KAUNO TECHNOLOGIJOS UNIVERSITETAS
INFORMATIKOS FUKULTETAS

Intelektikos pagrindai

(T120B029)

Laboratorinis darbas Nr. 2
Dirbtiniai neuroniniai tinklai

Darbą atliko:
IFF-7/14 gr. Studentas
Eligijus Kiudys

Darbą priėmė:
lekt. Andrius Nečiūnas
doc. Agnė Paulauskaitė-Tarasevičienė

KAUNAS 2020

Turinys

Įvadas

Tikslas
Įsisavinti dirbtinių neuroninių tinklų (DNT) kūrimo, testavimo ir pritaikymo metodus.

Uždaviniai:
1. Susipažinti su dirbtinio neuroninio tinklo (DNT) apmokymu, testavimu bei panaudojimu;
2. Susipažinti su prognozavimo uždavinio sprendimu panaudojant tiesinį dirbtinį neuroną;
3. Pritaikyti įgytas žinias kuriant modelį prognozavimo ar klasifikacijos uždaviniui spręsti.

Autoregresinis tiesinis modelis

Modelis, kuris realizuojamas esant prielaidai, kad priklausomybė tarp prognozuojamos reikšmės ir prieš tai esančių n elementų, gali būti aprašyta tiesine funkcija, vadinamas n-tosios eilės **autoregresiniu tiesiniu modeliu**. Autoregresinio modelio užduotis - laiko eilutės k-tosios reikšmės a(k) prognozavimas panaudojant n ankstesnes reikšmes a(k-1), a(k-2), ..., a(k-n).

Tiesinės autoregresijos modelio išraiška turi šią formą:
$\hat{a}(k) = w_1 \cdot a(k-1) + w_2 \cdot a(k-2) + \cdots + w_n \cdot a(k-n) + b$
Čia w_1, w_2, ..., w_n ir b modelio parametrai, o $\hat{a}(k)$ – prognozuojama reikšmė sekančiame žingsnyje.

Mūsų darbe autoregresinį modelį atitiks dirbtinis tiesinis neuronas, į kurį padavinėsime prieš tai buvusias n reikšmių. Modelio parametrai, neurono svoriniai koeficientai, prognozuos atsakymą, o prognozuojama reikšmė gausime neurono išėjime.
Prognozavimo klaidą k-tajame žingsnyje galime apskaičiuoti pagal formulę:
$e(k) = a(k) - \hat{a}(k)$
Čia $a(k)$ atitinka tikrąją reikšmę, o $\hat{a}(k)$ – prognozuojamą.

Turint istorinių duomenų rinkinį ieškosime optimalių autoregresinio modelio parametrų reikšmių. Tai reiškia, kad sieksime, jog $\hat{a}(k)$ prognozė, sugeneruota mūsų modelio pagalba, skirtus labai mažai nuo tikru rezultatų $a(k)$.

Uždavinio sprendimas panaudojant dirbtinį tiesinį neuroną

Užduotis:
Sudaryti saulės dėmių skaičiaus prognozės modelį, kuris remtųsi n ankstesnių metų duomenimis. Uždavinį spręsti pasitelkiant paprasčiausios struktūros DNT – vienetinis neuronas su tiesine aktyvacijos funkcija.

Užkrauname duomenų rinkinio sunspot.csv turinį ir nubrėžiame saulės dėmių aktyvumo už 1700 – 2014 metus grafiką.

```
import numpy as np
import Drawing as draw
from sklearn import datasets, linear_model, metrics


def ReadFile(fileName):
    tempYear = []
    sunSpotActivityTemp = []
    file = open(fileName, "r")
    for line in file.readlines():
        lineWithoutSpecial = line.strip()
        split = lineWithoutSpecial.split("\t")
        tempYear.append(int(split[0]))
        sunSpotActivityTemp.append(int(split[1]))
    return tempYear, sunSpotActivityTemp

year = []
sunSpotActivity = []
year, sunSpotActivity = ReadFile("sunspot.txt")
draw.DrowPlotSun(year, sunSpotActivity)
```

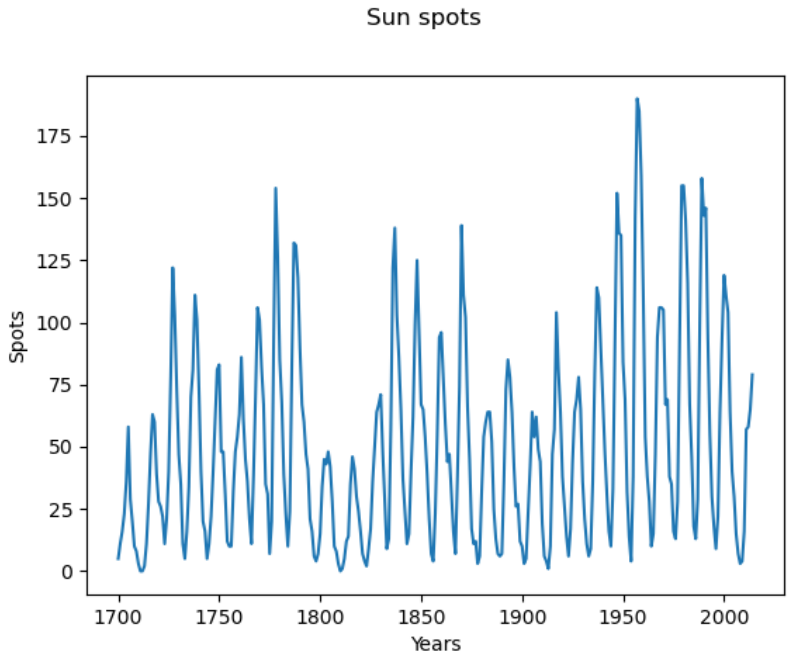

Pav 1. Saulės dėmių skaičiaus kitimo grafikas 1700-2014 metais

Priimdami, kad autoregresinio modelio eilė bus lygi 2 (n = 2), paruošiame neurono su dviem įvestimis mokymosi duomenų rinkinius P (įvesties duomenys) ir T (išvesties duomenys).

```
L = len(sunSpotActivity)
sunSpotActivityDataUsage = []
for a in range(L-2):
    sunSpotActivityDataUsage.append([int(sunSpotActivity[a]),
int(sunSpotActivity[a+1])])

answerForSunActivity = []
answerForSunActivityGraphic = []

for element in sunSpotActivity[2:]:
    answerForSunActivity.append([element])
    answerForSunActivityGraphic.append(element)
```

Įvesties ir išvesties duomenų rinkinių sąryšį pavaizduojame grafiškai (3D diagrama).

```
dataNormalized = normalizationFunction(sunSpotActivityDataUsage,
min(sunSpotActivityDataUsage)[0], max(sunSpotActivityDataUsage)[0])
dataAnswNormalized = normalizationFunction(answerForSunActivity,
min(answerForSunActivity)[0], max(answerForSunActivity)[0])


dataRes = []
dataRes.append([])
dataRes.append([])
for element in dataNormalized:
    dataRes[0].append(element[0])
    dataRes[1].append(element[1])

draw.DrowPlot3D(dataRes[0], dataRes[1], dataAnswNormalized)

import numpy as np
import matplotlib.pyplot as plot
from mpl_toolkits import mplot3d

def DrowPlot3D(x, y, z):
    fig = plot.figure()
    ax = fig.add_subplot(111, projection='3d')
    # ax.plot3D(x, y, z)
    ax.set_xlabel('2 years ago')
    ax.set_ylabel('1 years ago')
    ax.set_zlabel('This year')
    zline = np.array(x)
    xline = np.array(y)
    yline = np.array(z)
    ax.plot3D(xline, yline, zline)
    plot.suptitle('Connection between yearly spots')
    plot.show()
```

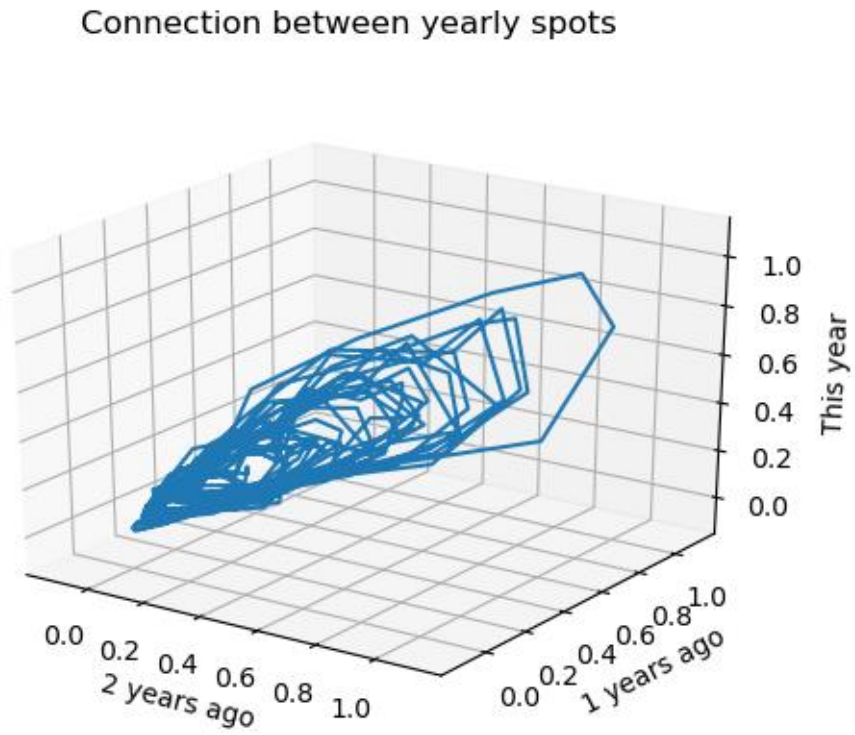

Pav 2. Grafinis įvesties ir išvesties duomenų rinkinių sąryšis

Optimalūs neurono svorio koeficientai aprašo lygtį plokštumos, geriausiai atitinkančios erdvės taškus.

Iš įvesties P ir išvesties T duomenų rinkinių išskiriame fragmentus Pu ir Tu, turinčius po 200 duomenų šablonų – apmokymo duomenų rinkinį. Remiantis šiuo duomenų rinkiniu apskaičiuosime optimalias neurono svorio koeficientų reikšmes (autoregresinio modelio parametrus).

```
dataForTraining = sunSpotActivityDataUsage[0:200]
dataForTrainingAnswer = answerForSunActivity[0:200]
```

Sukuriame dirbtinį neuroną ir apskaičiuojame jo svorio koeficientų reikšmes tiesioginiu metodu. Šiuo tikslu panaudojame apmokymo duomenų rinkinį Pu ir Tu.

```
from sklearn import linear_model
net = linear_model.LinearRegression()
net.fit(np.array(dataForTraining), np.array(dataForTrainingAnswer))
```

Gauname neurono svorio koeficientų reikšmes.

```
w1 = net.coef_[0][0]
w2 = net.coef_[0][1]
b = net.intercept_
print("Neurono Koficientai: ")
print("w1 = {}".format(w1))
print("w2 = {}".format(w2))
print("b = {}".format(b[0]))
```

w1 = -0.6760819763970695
w2 = 1.3715093938395846

b = 13. 40368324

Atliekame modelio verifikaciją – patikriname prognozavimo kokybę atlikdami neurono veikimo imitaciją. Pirmiausiai verifikacijai pasitelkiame apmokymo duomenų rinkinį, kuris buvo panaudotas svorio koeficientams apskaičiuoti.

```
Tsu = net.predict(dataForTraining)
```

Prognozavimo kokybę vertiname grafiškai sulygindami prognozės rezultatus ir tikrąsias reikšmes.

```
Tsu = net.predict(dataForTraining)

draw.DrawDiff(year[2:], sunSpotActivity[2:], Tsu)

def DrawDiff(Pu, Tu, Tsu):
    plot.plot(Pu, Tu, 'b', label='True values')
    plot.plot(Pu, Tsu, 'r', label='Predicted values')
    plot.xlabel('Years')
    plot.ylabel('Spots')
    plot.suptitle('Compare prediction with training set')
    plot.legend()
    plot.show()
```

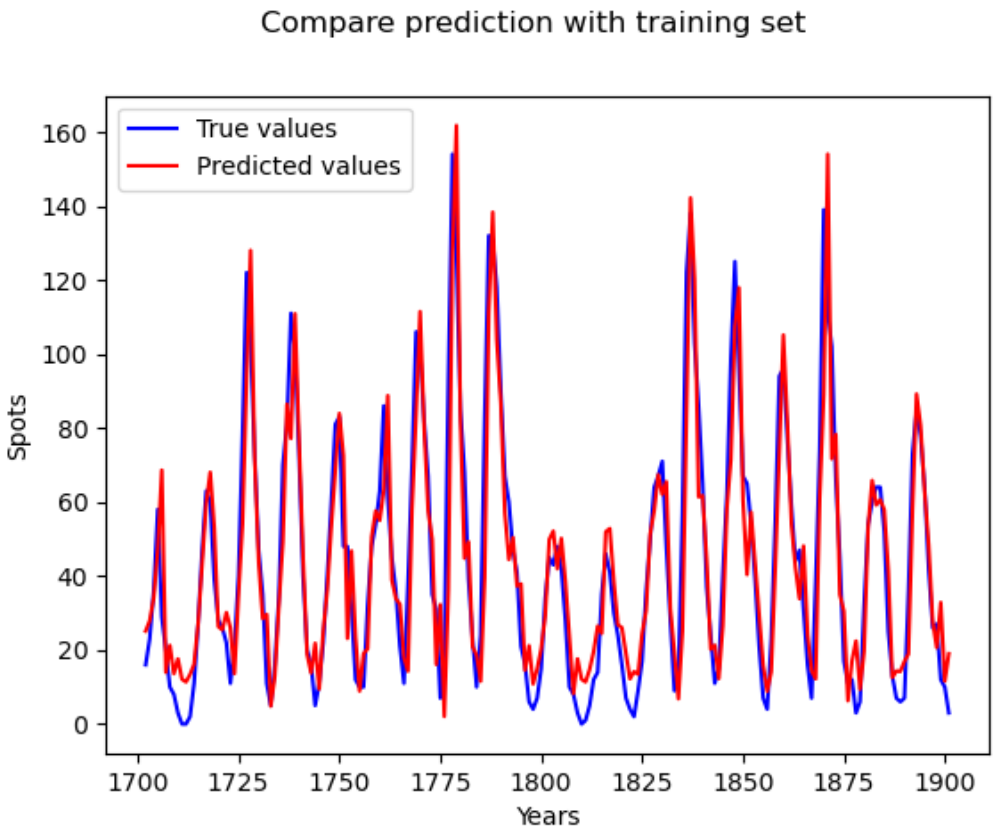

Pav 3. Prognozuojamas ir tikrasis saulės dėmių skaičius 1702-1901 metais

Verifikaciją atliekame su visu duomenų rinkiniu.

```
Ts = net.predict(sunSpotActivityDataUsage)

draw.DrawDiff(year[2:], sunSpotActivity[2:], Ts)
```

```
def DrawDiff(Pu, Tu, Tsu):
    plot.plot(Pu, Tu, 'b', label='True values')
    plot.plot(Pu, Tsu, 'r', label='Predicted values')
    plot.xlabel('Years')
    plot.ylabel('Spots')
    plot.suptitle('Compare prediction with training set')
    plot.legend()
    plot.show()
```

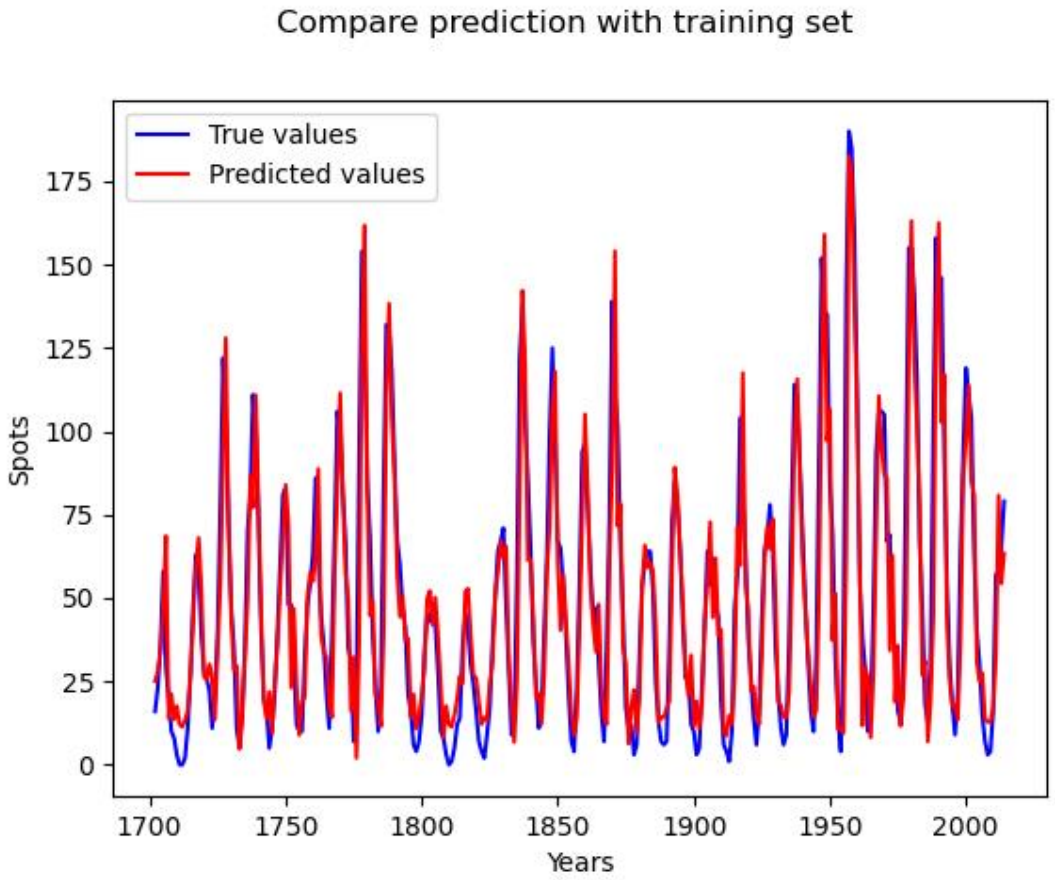

Pav 4. Prognozuojamas ir tikrasis saulės dėmių skaičius 1702–2014 metais (n = 2)

Sudarome prognozės klaidos vektorių bei jį pavaizduojame grafiškai.

```
eVector = list()
for real, predicted in zip(answerForSunActivity, Ts):
    print(predicted)
    e = real[0] - predicted[0]
    eVector.append(e)

draw.DrowPlot(year[2:], eVector)

def DrowPlot(x, answ):
    plot.plot(x, answ, 'r')
    plot.xlabel('Years')
    plot.ylabel('Error')
    plot.suptitle('Prediction error vector')
    plot.show()
```

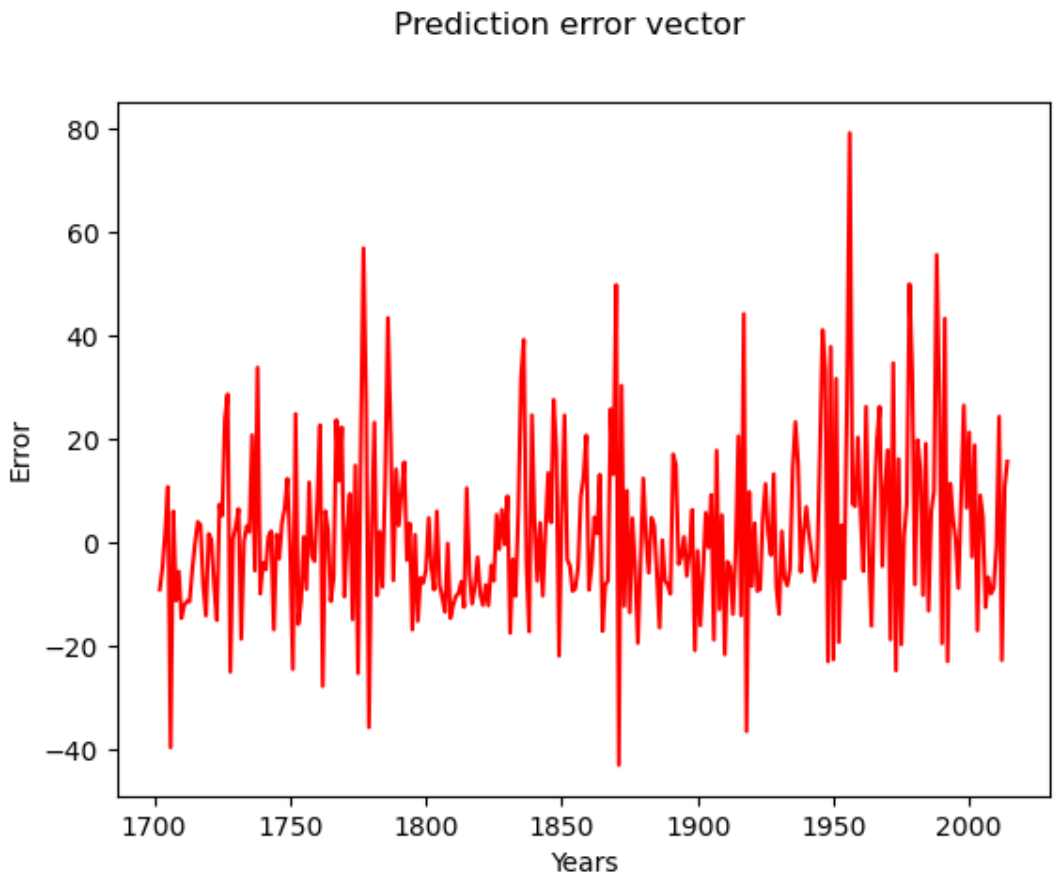

Pav 5. Saulės dėmių skaičiaus prognozavimo klaidos vektorius (n = 2)

Nubraižome prognozės klaidos histogramą.

```
draw.DrowHist(eVector)

def DrowHist(vect):
    plot.hist(vect, bins=20)
    plot.xlabel('Error')
    plot.ylabel('Frequency')
    plot.suptitle('Prediction error histogram')
    plot.show()
```

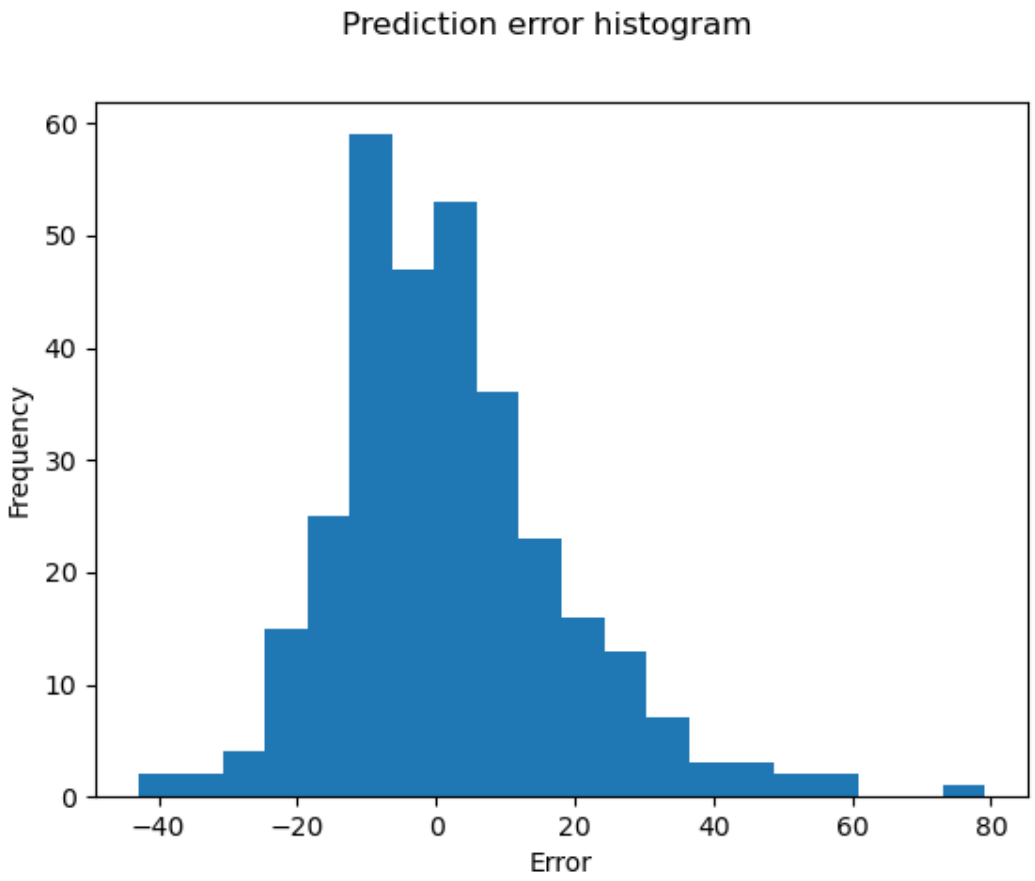

Pav 6. Saulės dėmių skaičiaus prognozės klaidų histograma (n = 2)

Apskaičiuojame vidutinės kvadratinės prognozės klaidos reikšmę (*eng. Mean-Square-Error* ***MSE***) ir prognozės absoliutaus nuokrypio medianą (*eng. Median-Absolute-Deviation,* ***MAD***).

$$MSE = \frac{1}{N}\sum_{k=1}^{N}(a(k) - \hat{a}(k))^2 = \frac{1}{N}\sum_{k=1}^{N}e(k)^2$$

MSE = 278.2687
MAD = 9.2189

MSE rodo paklaidos kvadratų vidurkį – tai gana gera metrika įvertinti visos prognozės tikslumą. Tuo tarpu **MAD** identifikuoja paklaidos reikšmę, apie kurią yra išsidėsčiusios paklaidos. **MAD** leidžia įvertinti prognozės paklaidą atmetant ekstremalias paklaidos reikšmes.

Toliau tą patį uždavinį sprendžiame sukurdami tiesinį neuroną, kuris svorinius koeficientus apskaičiuoja iteraciniu metodu.

Apibrėžiame maksimalų mokymosi žingsnių kiekį (*eng. Epochs*).

```
ep = 2000
```

Atliekame neurono apmokymą.

```
np.random.seed(1)

syn0 = 2 * np.random.random((2,1)) - 1
w_initialize = syn0
```

```
bias = np.random.randn()
b_initialize = bias
lr = 0.01 # geriausias kai bias naudojamas lr yra 0.1

data = np.array(dataForTrainingNormalized)
answerData = np.array(dataForTrainingAnswerNormalized)
print(data)


ep = 2000

for iter in range(ep):

    l0 = np.dot(data,syn0) + bias
    l1 = calcDirivAndE(l0)
    # how much did we miss?
    l1_error = np.subtract(l1, answerData)
    # l1_error = l1 - answerData
    # print(l1_error[0][0])
    print("Error:" + str(np.average(np.abs(l1_error))))
    # multiply how much we missed by the
    # slope of the sigmoid at the values in l1
    l1_delta = l1_error * calcDirivAndE(l1,True)
    # update weights and bias
    syn0 = syn0 - lr * np.dot(data.T, l1_delta)
    bias = bias - np.sum(lr * l1_delta)
```

Patikriname, kokios neurono svorio koeficientų reikšmės nusistovėjo po apmokymo.

```
print('Neurono svoriniai koeficientai prieš apmokymą:')
print("w1 = {}".format(w_initialize[0]))
print("w2 = {}".format(w_initialize[1]))
print("b  = {}".format(b_initialize))
print('----------')
print('Neurono svoriniai koeficientai:')
print("w1 = {}".format(syn0[0]))
print("w2 = {}".format(syn0[1]))
print("b  = {}".format(bias))
```

Neurono svoriniai koeficientai prieš apmokymą:
w1 = -0.165955990594852
w2 = 0.4406489868843162
b = -0.5281717522634557

Neurono svoriniai koeficientai:
w1 = -1.4991513019786302
w2 = 4.948811873011244
b = -2.042396766240324

Mokymosi procesas yra konverguojantis.

Atliekame saulės dėmių skaičiaus prognozę bei įvertiname jos paklaidą.

```
Ts = np.dot(dataNormalized, syn0) + bias
TsRes = calcDirivAndE(Ts)
TsDeNormalized = deNormalization(TsRes, min(answerForSunActivity)[0],
```

```
max(answerForSunActivity)[0])
print(len(TsDeNormalized))
print(len(answerForSunActivity))

eVector = np.subtract(answerForSunActivity, TsDeNormalized)

draw.DrowPlot(year[2:], eVector)
draw.DrowHist(eVector)

predictionMSE = mse(eVector)
predictionMAD = mad(eVector)

def mse(errors):
    if(len(errors) == 0):
        return None
    mseSum = 0
    for e in errors:
        mseSum += e*e
    return mseSum / len(errors)

def mad(errors):
    if(len(errors) < 2):
        return None
    absErrors = list(map(lambda x: abs(x), errors))
    absErrors.sort()
    index = int((len(absErrors) + 1) / 2)
    if(len(absErrors) % 2 == 0):
        result = absErrors[index - 1] + absErrors[index]
        return result / 2
    else:
        return absErrors[index - 1]

print('MSE = {}'.format(predictionMSE[0]))
print('MAD = {}'.format(predictionMAD[0]))
```

MSE = 390.12060647
MAD = 13.28116649

Epochs
Eksperimentai rodo, jog **epochs** parametro reikšmę didinant iki 300, prognozavimo kokybė gerėja. Esant didesnėms parametro reikšmėms, prognozavimo kokybė didėja bet nežymiai.

Learning-rate
Eksperimentai rodo, jog maksimali **lr** parametro reikšmė lygi 0.01. Esant didesnėms parametro reikšmėms procesas nekonverguoja.

Toliau saulės dėmių skaičių prognozuojame ne pagal praėjusių 2 ankstesnių metų (n = 2), o pagal 10 ankstesnių metų (n = 10).

Patikriname neurono svorio koeficientų reikšmes prieš apmokymą ir po jo.

Neurono svoriniai koeficientai prieš apmokymą:
w0 = -0.165955990594852
w1 = 0.4406489868843162
w2 = -0.9997712503653102
w3 = -0.39533485473632046

w4 = -0.7064882183657739
w5 = -0.8153228104624044
w6 = -0.6274795772446582
w7 = -0.3088785459139045
w8 = -0.20646505153866013
w9 = 0.07763346800671389
b = 9

Neurono svoriniai koeficientai:
w0 = -0.165955990594852
w1 = 0.4406489868843162
w2 = -0.9997712503653102
w3 = -0.39533485473632046
w4 = -0.7064882183657739
w5 = -0.8153228104624044
w6 = -0.6274795772446582
w7 = -0.3088785459139045
w8 = -0.20646505153866013
w9 = 0.07763346800671389
b = -2.030767208503895

Atliekame neurono verifikaciją su visu duomenų rinkiniu

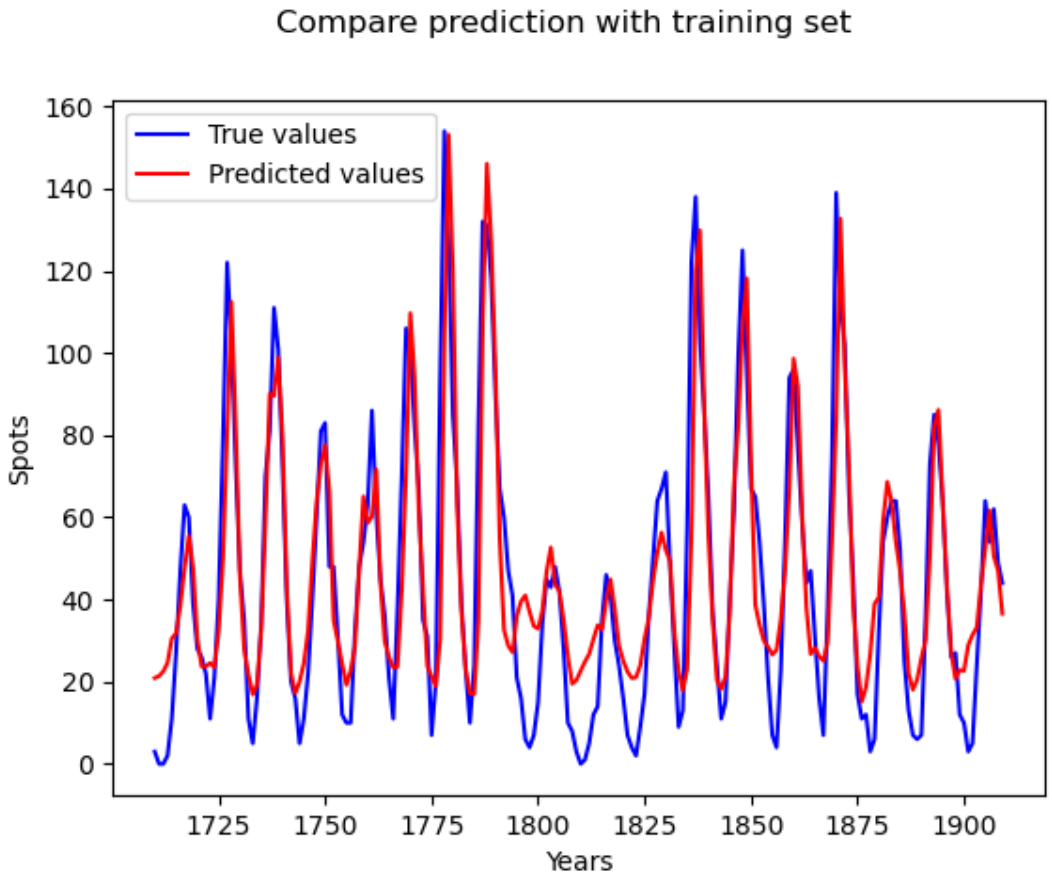

Pav 7. Prognozuojamas ir tikrasis saulės dėmių skaičius 1702–2014 metais (n = 10).

Sudarome prognozės klaidos vektorių bei jį pavaizduojame grafiškai.

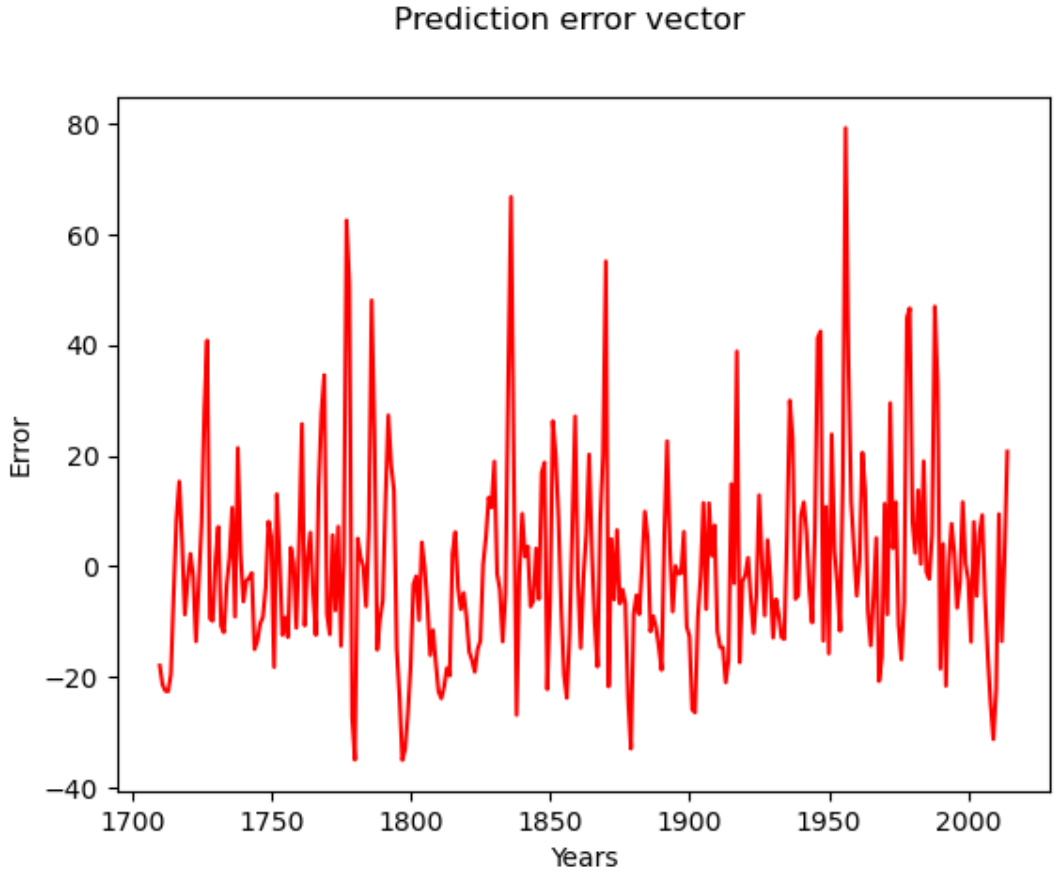

Pav 8. Saulės dėmių skaičiaus prognozavimo klaidos vektorius (n = 10)

Nubraižome prognozės klaidos histogramą.

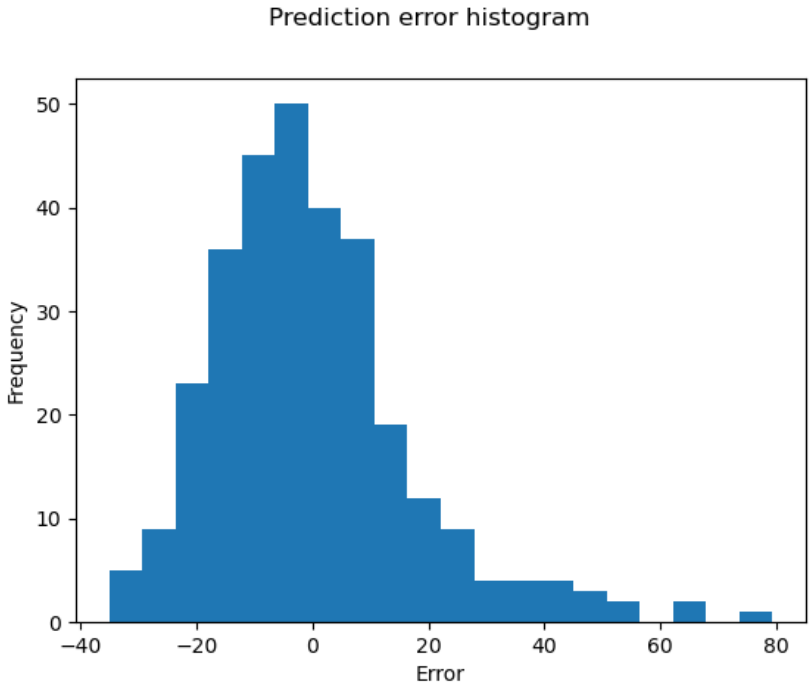

Pav 9. Saulės dėmių skaičiaus prognozės klaidų histograma (n = 10)

MSE = 303.40786860251933
MAD = 9.696342699852416

Tiek grafinė prognozės rezultatų analizė (7-9 pav.), tiek ir skaitinės charakteristikos (MSE ir MAD) rodo, jog remiantis 10 pastarųjų metų duomenimis galime padaryti geresnę prognozę nei darant pagal dviejų pastarųjų metų duomenis naudojant bibliotekas. Naudojant mano sukurtą modelį matome, kad rezultatai žymiai suprastėjo.

Prognozavimo ir klasifikacijos modelių kūrimas

Pasirinktas duomenų rinkinys:

Duomenų rinkinys	
Įrašų kiekis	68785
Atributų kiekis	20
Naudojamų atributų kiekis	19
Tolydinio tipo atributų kiekis	17
Kategorinio tipo atributų kiekis	2
Tolydus atributai	
Trukmė (angl. Duration)	
Plotis (angl. Width)	
Aukštis (angl. Height)	
Pralaidumas (angl. Bitrate)	
Kadrų dažnis (angl. Framerate)	
I (angl. I)	
P (angl. P)	
Kadrai (angl. Frames)	
I_dydis (angl. I_size)	
P_dydis (angl. P_size)	
Dydis (angl. Size)	
Išėigos pralaidimas (angl. O_bitrate)	
Išeigos kadrų dažnis (angl. O_framerate)	
Išeigos plotis (angl. O_width)	
Išeigos aukštis (angl. O_height)	
Sunaudotas RAM kiekis (angl. Umem)	
Užtruktas laikas (angl. Utime)	
Kategoriniai atributai	
Kodekas (angl. Codec)	
Konvertuotas Kodekas (angl. O_codec)	

Pasirinkau kaip rezultata Trukmė (angl. Duration) atributą, Ir bandau spėti su I ir Framerate atributais

Duomenų rinkinio fragmentas:

id	duration	codec	width	height	bitrate	framerate	i	p	frames	i_size
04t6-jw9czg	130.3567	mpeg4	176	144	54590	12	27	1537	1564	64483
04t6-jw9czg	130.3567	mpeg4	176	144	54590	12	27	1537	1564	64483
04t6-jw9czg	130.3567	mpeg4	176	144	54590	12	27	1537	1564	64483
04t6-jw9czg	130.3567	mpeg4	176	144	54590	12	27	1537	1564	64483

p_size	size	o_codec	o_bitrate	o_framerate	o_width	o_height	umem	utime
825054	889537	mpeg4	56000	12	176	144	22508	0
825054	889537	mpeg4	56000	12	320	240	25164	0.98
825054	889537	mpeg4	56000	12	480	360	29228	1.216
825054	889537	mpeg4	56000	12	640	480	34316	1.692

Duomenų analizė:

Tolydinio tipo atributai

Atributo pavadinimas	Kiekis (Eilučių sk.)	Trūkstamos reikšmės, %	Kardinalumas	Minimali reikšmė	Maksimali reikšmė	1-asis kvartilis	3-asis kvartilis	Vidurkis	Mediana	Standartinis nuokrypis
duration	68784	0	1086	31.08	25844.09	106.765	379.32	286.4139	239.1417	287.2556
width	68784	0	6	176	1920	320	640	624.9342	480	463.1657
height	68784	0	6	144	1080	240	480	412.5722	360	240.6137
bitrate	68784	0	1095	8384	7628466	134334	652967	693701.5	291150	1095620
framerate	68784	0	261	5.705752	48	15	29	23.24132	25.02174	7.224795
i	68784	0	306	7	5170	39	138	100.8683	80	84.76417
p	68784	0	1042	175	304959	2374	9155	6531.692	5515	6075.828
frames	68784	0	1044	192	310129	2417	9232	6641.708	5628	6153.298
i_size	68784	0	1099	11648	90828552	393395	3392479	2838987	945865	4325105
p_size	68784	0	1099	33845	7.69E+08	1851539	15155062	22180569	6166260	50972691
size	68784	0	1099	191879	8.07E+08	2258222	19773349	25022942	7881069	54143622
o_bitrate	68784	0	7	56000	5000000	109000	3000000	1395036	539000	1749339
o_framerate	68784	0	5	12	29.97	15	25	21.19086	24	6.668654
o_width	68784	0	6	176	1920	320	1280	802.3364	480	609.9554
o_height	68784	0	6	144	1080	240	720	503.8255	360	315.9681
umem	68784	0	9395	22508	711824	216820	219656	228224.7	219480	97430.17
utime	68784	0.004361	10960	0.184	224.574	2.096	10.433	9.996134	4.408	16.1076

Kategorinio tipo atributai

Atributo pavadinimas	Kiekis (Eilučių sk.)	Trūkstamos reikšmės, %	Kardinalumas	Moda	Modos dažnumas	Moda, %	2-oji Moda	2-osios Modos dažnumas	2-oji Moda, %
codec	68784	0	4	h264	31545	45.86096	vp8	18387	26.73151
o_codec	68784	0	4	mpeg4	17291	25.13811	vp8	17277	25.11776

Atliekame duomenų rinkinio pertvarkymą:

1. Pašalinamas atributas **id.**;
2. Pašalinami visi atributai, turintys reikšmių trūkumą didesnį kaip 60 proc.;
3. Atliekame tolydinio tipo atributų ekstremalių reikšmių korekciją;
4. Tuščias atributų reikšmes keičiame vidrukiu/moda;
5. Kategorinio tipo kintamuosius su Python paverčiau į tolydinio tipo kintamuosius naudodamas Dictionary mapping pvz. („MPEG4“=1, “H264”=2, “VP8”=3, “FLV”=4).
6. Naudojantis funkcija normaliztaion() atliekame įvesties atributų normalizavimą.

Sukuriame dirbtinį neruononį tinklą (DNT), sudarytą iš vieno neurono.

```
iDataNormalize = normalizationFunction(dataWithEmpty['i'],
min(dataWithEmpty['i']), max(dataWithEmpty['i']))
framerateDataNormalize = normalizationFunction(dataWithEmpty['framerate'],
```

```
min(dataWithEmpty['framerate']), max(dataWithEmpty['framerate']))
dataZip = zip(iDataNormalize, framerateDataNormalize) # maybe use with all of
this p
dataNormalized = list(dataZip)
res = dataWithEmpty['duration']
resData = []
for element in res:
    resData.append([element])
resNormalized = normalizationFunction(dataWithEmpty['duration'],
min(dataWithEmpty['duration']), max(dataWithEmpty['duration']))

resDataNormalized = []
for element in resNormalized:
    resDataNormalized.append([element])
# print(dataNormalized[0:10])

np.random.seed(1)
data = np.array(dataNormalized)
answerData = np.array(resDataNormalized) # fix answer data
# print(dataSec)
folds = 10
dataSplitedForCross = np.array(np.array_split(data, folds))
answSplitedForCross = np.array(np.array_split(answerData, folds))

ep = 100
batch = 10

listOfErrors = []
for elements in range(folds):

    trainData = []
    trainRes = []
    if(folds > 1):
        cnt = 0
        for merge in range(folds):
            if (cnt > 0 and (merge < elements or merge > elements)):
                trainData = np.concatenate((trainData,
dataSplitedForCross[merge]), axis=0)
                trainRes = np.concatenate((trainRes,
answSplitedForCross[merge]), axis=0)

            if(cnt == 0 and merge < elements):
                trainData = dataSplitedForCross[0]
                trainRes = answSplitedForCross[0]
                cnt += 1
            elif(cnt == 0 and merge > elements):
                trainData = dataSplitedForCross[merge]
                trainRes = answSplitedForCross[merge]
                cnt += 1
    elif (folds <= 1):
        trainData = data
        trainRes = answerData

    syn0 = 2 * np.random.random((2, 1)) - 1
    w_initialize = syn0
    bias = np.random.randn()
    b_initialize = bias
    lr = 0.01  # geriausias kai bias naudojamas lr yra 0.1
    batch_Count = 0
```

```
    for iter in range(ep):  # epochs
        #
        # forward propagation
        l0 = np.dot(trainData, syn0) + bias  # privalo buti atskirta
        l1 = calcDirivAndE(l0)
        # how much did we miss?
        l1_error = l1 - trainRes
        # print(l1_error[0][0])
        print("Error:" + str(np.average(np.abs(l1_error))))
        # multiply how much we missed by the
        # slope of the sigmoid at the values in l1
        l1_delta = l1_error * calcDirivAndE(l1, True)
        # update weights
        if batch_Count == batch:
            syn0 = syn0 - lr * np.dot(trainData.T, l1_delta)
            bias = bias - np.sum(lr * l1_delta)
            batch_Count = 0
        elif batch_Count < batch:
            batch_Count += 1

    l0 = np.dot(dataSplitedForCross[elements], syn0) + bias
    l1 = calcDirivAndE(l0)
    error = np.average(np.abs(answSplitedForCross[elements] - l1))
    listOfErrors.append(error)


print('Neurono svoriniai koeficientai prieš apmokymą:')
print("vidutinis tikslumas = {}".format(np.average(listOfErrors)))
print("standartintis nuokrypit = {}".format(Deviation(listOfErrors)))

Ts = np.dot(dataNormalized, syn0) + bias
TsRes = calcDirivAndE(Ts)
TsDeNormalized = deNormalization(TsRes, min(dataWithEmpty['duration']),
max(dataWithEmpty['duration']))

# print(len(TsDeNormalized))
# print(len(answerForSunActivity))
#

eVector = list()
for real, predicted in zip(answerData, TsDeNormalized):
    e = real[0] - predicted[0]
    eVector.append(e)
#
# draw.DrowPlot(year[2:], eVector)
# draw.DrowHist(eVector)
#
predictionMSE = mse(eVector)
predictionMAD = mad(eVector)
print('MSE = {}'.format(predictionMSE))
print('MAD = {}'.format(predictionMAD))
```

activation = gradient
loss = paprasta atimtis
lr = 0.01
batch_size = 10
epochs = 100

Atliekame 10 intervalų kryžminę patikrą.

Nr.	Tikslumas
1	0.008447905483476157
2	0.012776881680165046
3	0.007749118248355562
4	0.007365232564556326
5	0.009719445008227433
6	0.012584542192754171
7	0.007539158650896745
8	0.006085093118854678
9	0.00841685239046468
10	0.01823301132023518

Kryžminės patikros rezultatai:
vidutinis tikslumas = 0.009891724065798597
standartinis nuokrypis = 0.003470460168465797
MSE = 965.3517550339798
MAD = 31.071939657860845

Lentelėje pateikiamos išbandytos kiekvieno parametro reikšmės (viso 216 kombinacijų).

Parametras	**Išbandytos reikšmės**			
Batch size	10	25	32	50
Epochs	100	500	1000	2000
Lr	0.0	0.1	0.01	0.001
Folds	1	10	10	10

```
np.random.seed(1)
data = np.array(dataNormalized)
answerData = np.array(resDataNormalized) # fix answer data
# print(dataSec)
folds = 10
ep = 1000
batch = 25
lr = 0.01  # geriausias kai bias naudojamas lr yra 0.1
batch_Count = 0

dataSplitedForCross = np.array(np.array_split(data, folds))
answSplitedForCross = np.array(np.array_split(answerData, folds))

listOfErrors = []
for elements in range(folds):

    trainData = []
    trainRes = []
    if(folds > 1):
        cnt = 0
        for merge in range(folds):
            if (cnt > 0 and (merge < elements or merge > elements)):
                trainData = np.concatenate((trainData,
dataSplitedForCross[merge]), axis=0)
                trainRes = np.concatenate((trainRes,
answSplitedForCross[merge]), axis=0)

            if(cnt == 0 and merge < elements):
                trainData = dataSplitedForCross[0]
                trainRes = answSplitedForCross[0]
                cnt += 1
            elif(cnt == 0 and merge > elements):
                trainData = dataSplitedForCross[merge]
                trainRes = answSplitedForCross[merge]
                cnt += 1
    elif (folds <= 1):
        trainData = data
        trainRes = answerData

    syn0 = 2 * np.random.random((2, 1)) - 1
    w_initialize = syn0
    bias = np.random.randn()
    b_initialize = bias
    for iter in range(ep):  # epochs
        #
        # forward propagation
        l0 = np.dot(trainData, syn0) + bias  # privalo buti atskirta
        l1 = calcDirivAndE(l0)
        # how much did we miss?
```

```
        l1_error = l1 - trainRes
        # print(l1_error[0][0])
        print("Error:" + str(np.average(np.abs(l1_error))))
        # multiply how much we missed by the
        # slope of the sigmoid at the values in l1
        l1_delta = l1_error * calcDirivAndE(l1, True)
        # update weights
        if batch_Count == batch:
            syn0 = syn0 - lr * np.dot(trainData.T, l1_delta)
            bias = bias - np.sum(lr * l1_delta)
            batch_Count = 0
        elif batch_Count < batch:
            batch_Count += 1

    l0 = np.dot(dataSplitedForCross[elements], syn0) + bias
    l1 = calcDirivAndE(l0)
    error = np.average(np.abs(answSplitedForCross[elements] - l1))
    listOfErrors.append(error)



print('Neurono svoriniai koeficientai prieš apmokymą:')
print("vidutinis tikslumas = {}".format(np.average(listOfErrors)))
print("standartintis nuokrypit = {}".format(Deviation(listOfErrors)))

print(listOfErrors)

Ts = np.dot(dataNormalized, syn0) + bias
TsRes = calcDirivAndE(Ts)
TsDeNormalized = deNormalization(TsRes, min(dataWithEmpty['duration']),
max(dataWithEmpty['duration']))

# print(len(TsDeNormalized))
# print(len(answerForSunActivity))
#

eVector = list()
for real, predicted in zip(answerData, TsDeNormalized):
    e = real[0] - predicted[0]
    eVector.append(e)
#
# draw.DrowPlot(year[2:], eVector)
# draw.DrowHist(eVector)
#
predictionMSE = mse(eVector)
predictionMAD = mad(eVector)
print('MSE = {}'.format(predictionMSE))
print('MAD = {}'.format(predictionMAD))
```

Optimalios parametrų reikšmės:

- Batch size = 32
- Epochs = 1000
- Learning(Lr) = 0.01
- Folds = 10

Atliekame pakeisto modelio 10 intervalų kryžminę patikrą.

Nr.	Tikslumas
1	0.008447905483476157
2	0.012776881680165046
3	0.007749118248355562
4	0.007365232564556326
5	0.009719445008227433
6	0.012584542192754171
7	0.007539158650896745
8	0.006085093118854678
9	0.00841685239046468
10	0.01823301132023518

Kryžminės patikros rezultatai:
vidutinis tikslumas = 0.00989163527370002
standartinis nuokrypis = 0.005290562461473264
MSE = 965.3517550339798
MAD = 31.071939657860845

Išvados

1. Dirbtinių neuroninių tinklų (DNT) tinkamas naudojimas gali padėti išspręsti uždavinius, kurių sprendimo neįmanoma aprašyti alogritmiškai.
2. Teisingai panaudojant DNT, galima sudaryti prognozės modelį tarp iš pirmo žvilgsnio nepriklausomų atributų. Sudarant Čilės plebiscito visuomenės nuomonės apklausos klasifikacijos modelį, buvo pasiektas blogas tikslumas, nors atliekant duomenų analizę, sąryšis buvo didelis.
3. Didesnis DNT įvesčių skaičius („ilgesnis“ šablonas) gali padėti pasiekti geresnį prognozės rezultatą. Tai galime pastebėti sudarydami skirtingos eilės saulės dėmių skaičiaus prognozės modelį.
4. Didesnis mokymosi ciklų (*eng. Epochs*) skaičius nebūtinai sąlygoja geresnę apsimokymo kokybę – įvyksta persimokymas.
5. Kaip rodo vaido įrašų modelis, prognozės/klasifikacijos tikslumą galime pagerinti pataisan mokymosi konstantą ir eopochų dydį.
6. Optimalių modelio parametrų paieška (*eng. Paremeter Tunning*) gali padėti pasiekti dar didesnį modelio tikslumą. Tiesa pagerėjimas dažnai gali būti tik nežymus kaip ir matome paskutiniame punkte.
7. Neuroninis tinklas rašytas nuo nulio yra efektyvus kai datos kiekis yra mažas. Toks neuronins tinklas padeda suprasti kaip viskas veikias bet dažniausiai nėra efektyvus kadangi bibliotekos yra suoptimizuotos ir geriau bei greičiau veikia.