KAUNO TECHNOLOGIJOS UNIVERSITETAS
INFORMATIKOS FUKULTETAS

# Intelektikos pagrindai

*(T120B029)*

## Laboratorinis darbas Nr. 4

### Duomenų klasifikavimas K-vidurkių metodu

Darbą atliko:
IFF-7/14 gr. Studentas
Eligijus Kiudys

Darbą priėmė:
lekt. Andrius Nečiūnas
doc. Agnė Paulauskaitė-Tarasevičienė

KAUNAS 2020

# Turinys

# Darbo užduoties aprašas, įrankių pasirinkimas

Pasirinkti duomenų rinkinį (apie 100-300 duomenų) kuriame būtų pateikiami bent 6 tolydiniai atributai (kategoriniai atributai netinka). Duomenų rinkinys gali neturėti išvesties atributo, nes tai neprižiūrimo mokymo algoritmas. Naudojantis pasirinktu duomenis juos suklasterizuoti į dviejų, trijų ir keturių klasterių dydžius atliekant po tris eksperimentus su skirtingomis poromis naudojant K-vidurkių algoritmą.

Užduoties sprendimui yra naudojamas K-vidurkių algoritmas, kuris yra realizuotas naudojant Python programavimo kalbą.

Naudojamos Python bibliotekos laboratoriniame darbe:

1. Numpy – darbui su masyvais ir papildomiems skaičiavimams.
2. Matplotlib – grafikų braižymui.
3. Pandas – HeatMap datos sutvarkymui.
4. Math – matematiniams skaičiavimams.
5. Seaborn – HeatMap braižymui.

Šiame laboratoriniame darbe pasirinkau NBA 2014-2015 metų pilną žaidėjų statistiką

# Įvestys bei išvestis

## Įvestys

NBA 2014-2015 metų pilną žaidėjų statistiką. Žemiau įdėta lentelė su pasirinktais duomenimis ir jų paaiškinimais.

| | |
|---|---|
| Žaista žaidimų (angl. Played Games) | Žaidėjo žaistų žaidimų kiekis |
| MIN | Žaistų minučių kiekis |
| PTS | Taškų kiekis |
| FGM | Pataikytu dvitaškių kiekis |
| FGA | Mestų dvitaškių kiekis |
| FG% | Dvitaškių pataikymo procentas |
| 3PM | Pataikytu tritaškių kiekis |
| 3PA | Mestų tritaškių kiekis |
| 3P% | Tritaškių pataikymo procentas |
| FTM | Pataikytų baudų kiekis |
| FTA | Mestų baudų kiekis |
| FT% | Mestų baudų procentas |
| OREB | Atkovoti kamuoliai po kitos komandos krepšiu |
| DREB | Atkovoti kamuoliai po savo komandos krepšiu |
| REB | Bendrai atkovoti kamuoliai |
| AST | Rezultatyvus kamuolio perdavimas kitam komandos žaidėjui |
| STL | Pavogtų kamuolių kiekis |
| BLK | Blokų kiekis |
| TOV | Prarastų kamuolių kiekis |
| PF | Pražangų kiekis |
| EFF | Efektyvumo reitingas |

*Lentelė. 1 Naudojamų duomenų paaiškinimas*

Susidarome koreliacijos matricą, pagal kurią sprendžiame kokius duomenis naudosime.

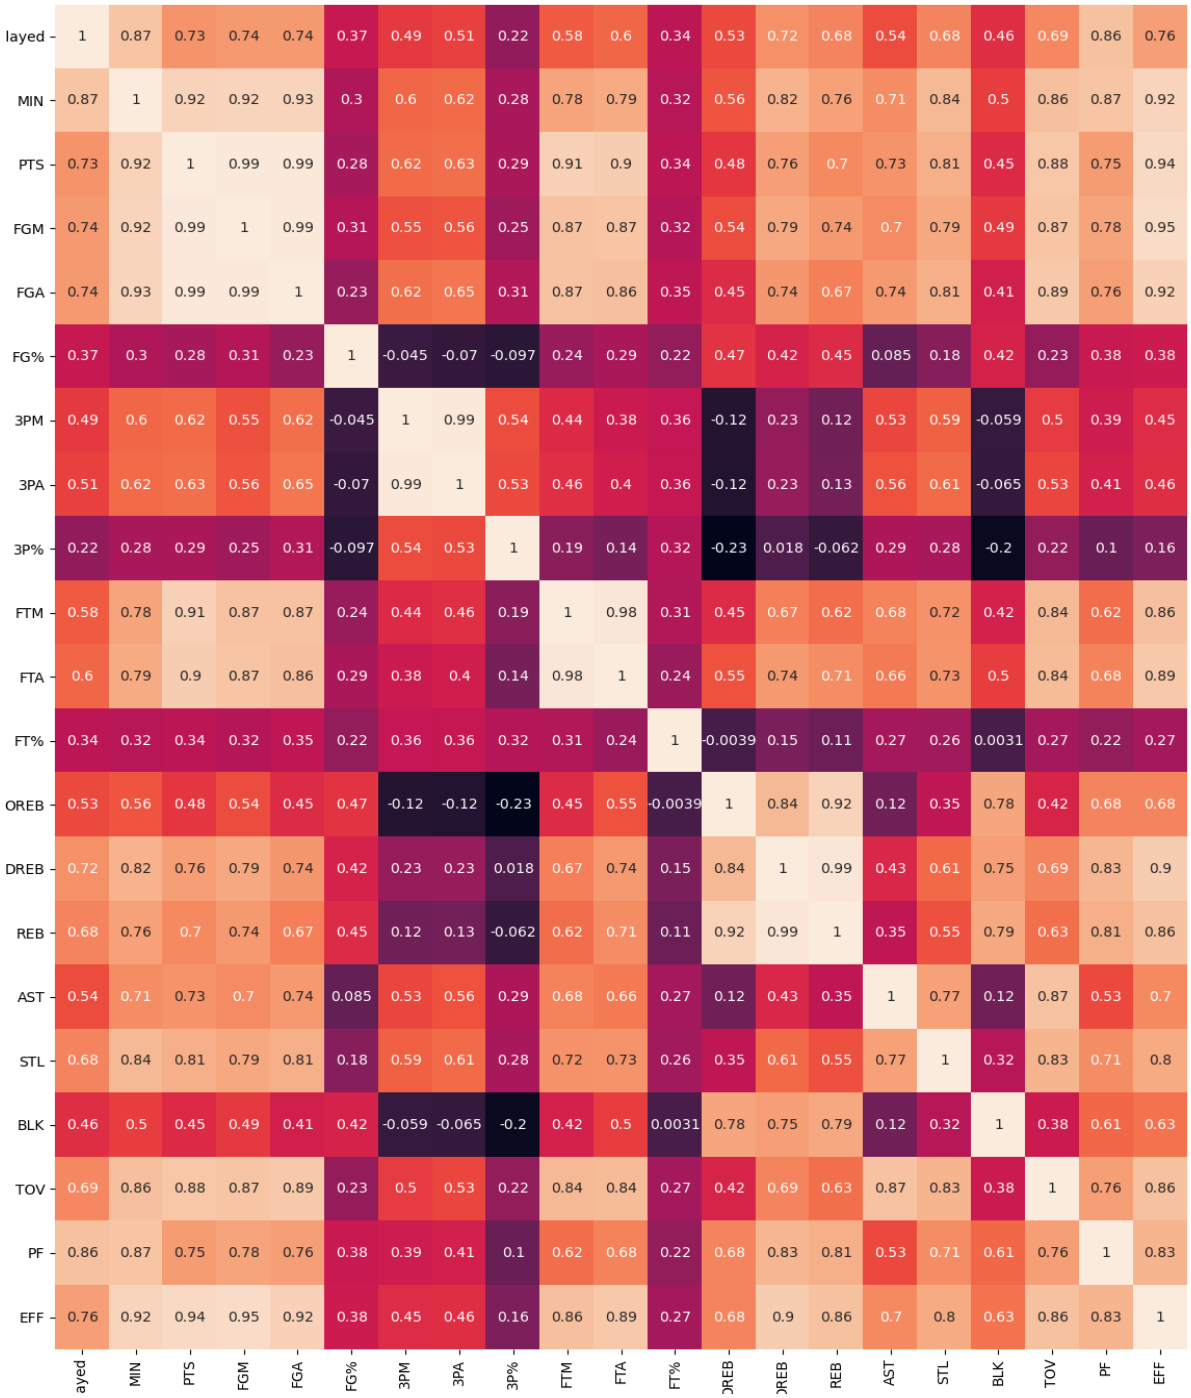


*Pav. 1 Koreliacijos matrica*

Atsižvelgiant į koreliacijos matricą sudarėme naudojamas poras. Poros buvo nustatytos pagal mažiausią koeficientą kadangi šitame laboratoriniame darbe duomenis reikia sugrupuoti į atskiras grupes.

| X | Y |
|---|---|
| 3P% | OREB |
| 3PM | BLK |
| 3PA | STL |

*Lentelė. 2 Pasirinktos poros*

## Išvestys

Suskirstytos pasirinktos poros į dvi, tris ir keturias grupes naudojant K-mean algoritmą. Pirmiausia suklasterizuojame pasirinktus duomenis į du klasterius. Pradinius centroidu taškus pasirenku toliausius taškus tarpusavyje.

Detalesnius grafikus galima matyti Modelio analizėje.

### Klasterizavimas į du klasterius

Klasterizavimui naudojama pora, tritaškių metimo procentai ir atkovoti kamuoliai po kitos komandos krepšiu. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

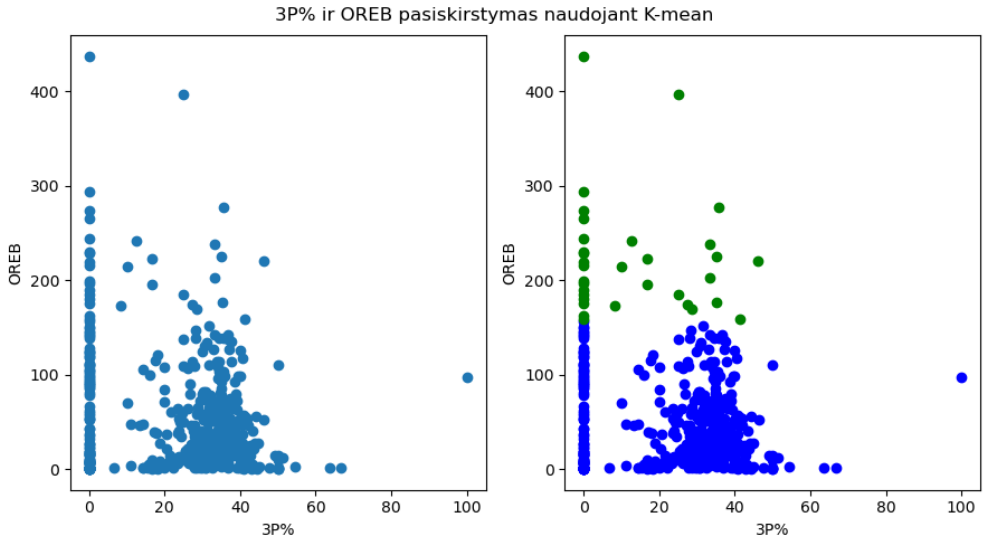


*Pav. 2 Duomenų klasterizavimas į du klasterius*

Atlikę klasterizavimą galime pastebėti jog sugrupuota buvo pavienės reikšmės į vieną grupę, o taškai kurie yra vienas arti kito į kitą grupę

Klasterizavimui naudojama pora, įmestų tritaškių kiekis ir blokuoti metimai. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

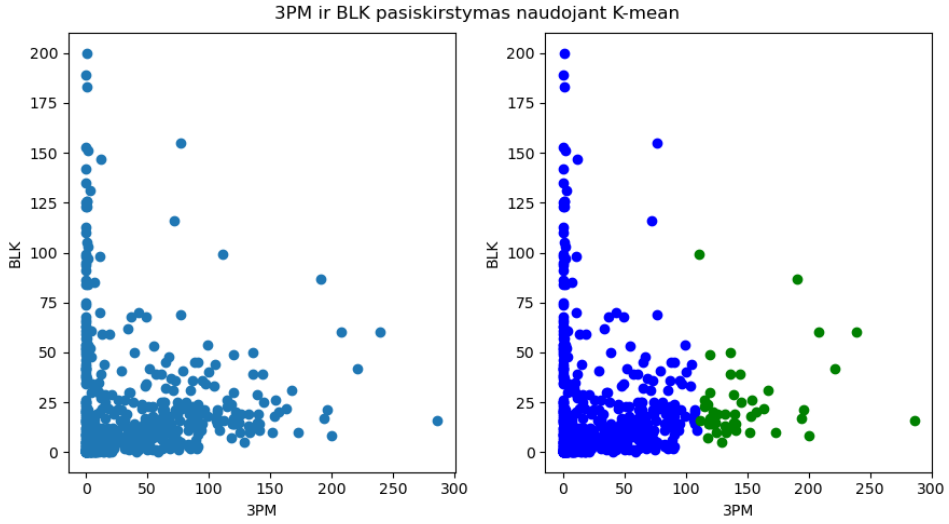


*Pav. 3 Duomenų klasterizavimas į du klasterius*

Atlikę klasterizavimą matome kad duomenų grupavimas įvyko toje vietoje kur yra mažiausia taškų. Būtent toje vietoje grafikas buvo perskeltas per pusę ir taip duomenys yra suskirstyti į dvi dalis.

Klasterizavimui naudojama pora yra mestų tritaškių kiekis ir pavogtų kamuolių kiekis. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

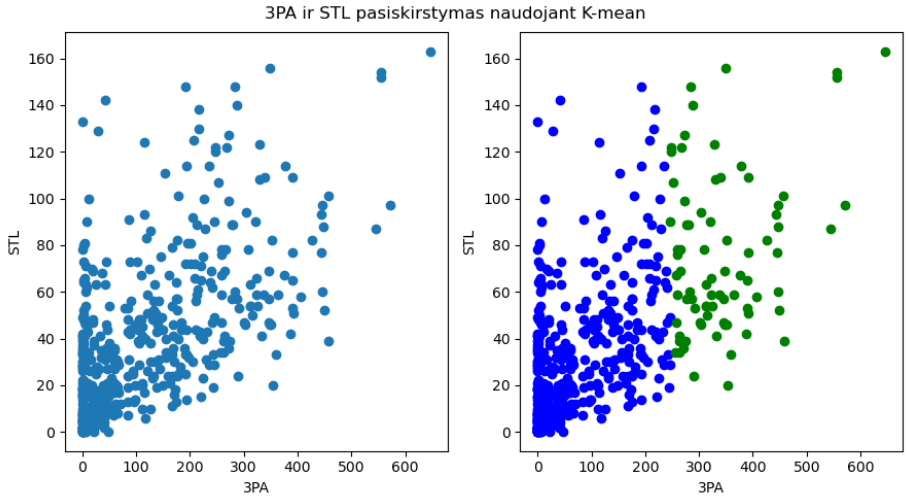


*Pav. 4 Duomenų klasterizavimas į du klasterius*

Panaudojus klasterizavimą matomas kitos rezultatas kadangi duomenys pasiskirstę vienodžiau ir per visą grafiką. Kadangi imamas dviejų klasterių ir toliausių taškų centroidai matome kad duomenų pasiskirstymas skyla į dvi dalis per grafiko vidurį.

**Klasterizavimas į tris klasterius**

Klasterio centroidams naudojau tris tolygiai paskirstytus taškus, jie pasirenkami iš išrikiuotų taškų sąrašo.

Pirmam bandymui naudojama pora, tritaškių metimo procentai ir atkovoti kamuoliai po kitos komandos krepšiu. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

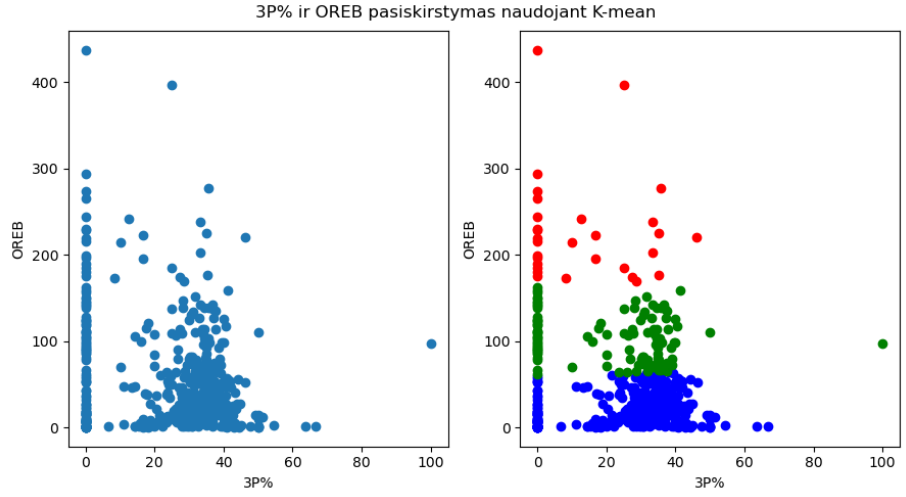


*Pav. 5 Duomenų klasterizavimas į tris klasterius*

Klasterizavus duomenis pastebime, kad tendencija nesikeičia, duomenys išskaidomi pagal centroid taškus kurie pasiskirstę daugmaž tolygiai. Duomenų kiekiai sudarytos grupėse skiriasi kadangi pasiskirstymas grafike nėra vienodas.

Antram bandymui naudojama pora, įmestų tritaškių kiekis ir blokuoti metimai. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

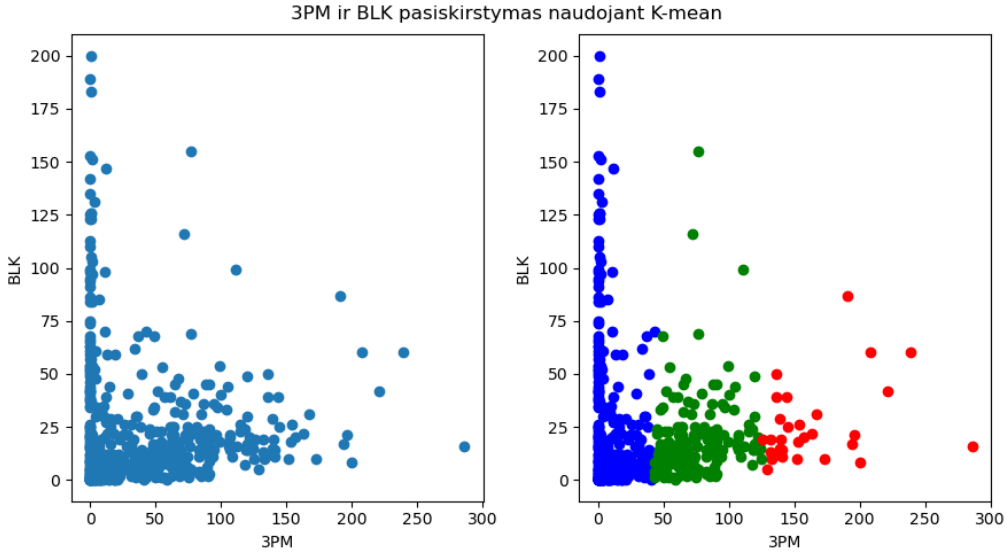


*Pav. 6 Duomenų klasterizavimas į tris klasterius*

Suskirsčius duomenis į tris dalis matome jog duomenys pasiskirstę yra netolygiai, primoje grupėje yra daugiausia taškų, antroje grupėje vidutiniškai ir trečioje mažiausia. Toks pasiskirstymas susidarė kadangi atstumas tarp centroidų yra panašus. Taškai susiskirstę į netolygias grupes dėl to nes taškų pasiskirstymas grafike nėra tolygus.

Trečiam bandymui naudojama pora yra mestų tritaškių kiekis ir pavogtų kamuolių kiekis. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

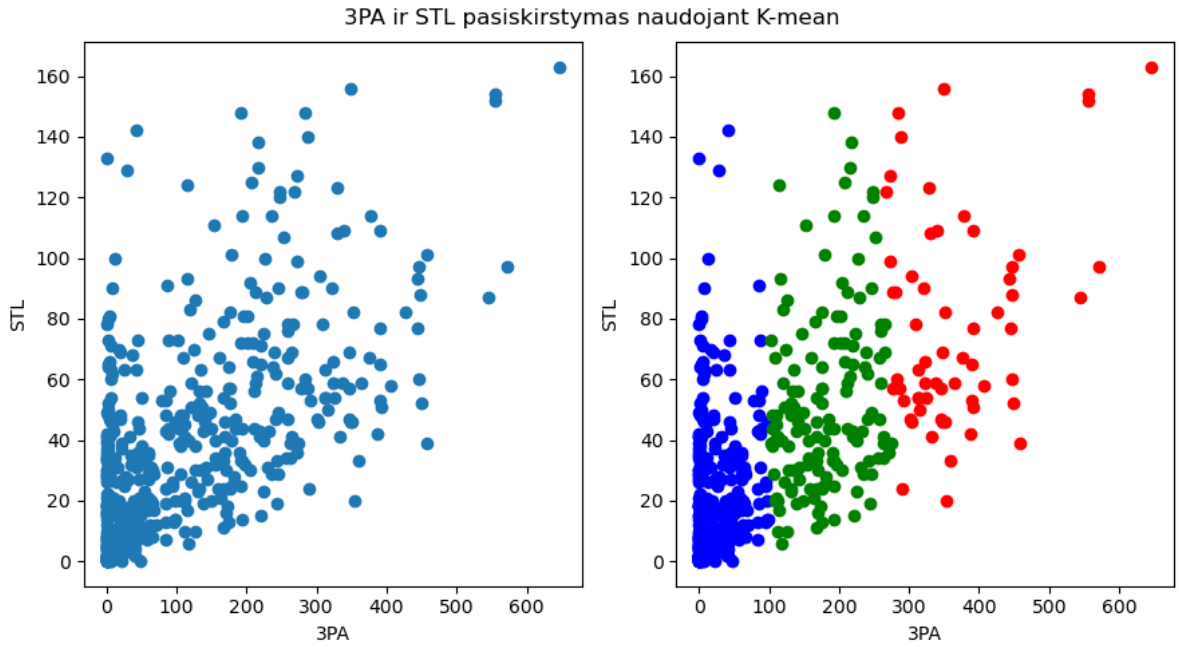


*Pav. 7 Duomenų klasterizavimas į tris klasterius*

Trečiame bandyme matome jog duomenys išskaidomi panašiai. Toks išskaidymas į grupes mums pasako jog taškų išsiskaidymas grafike yra panašus.

**Klasterizavimas į keturis klasterius**

Pirmam bandymui naudojama pora yra tritaškių metimo procentai ir atkovoti kamuoliai po kitos komandos krepšiu. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

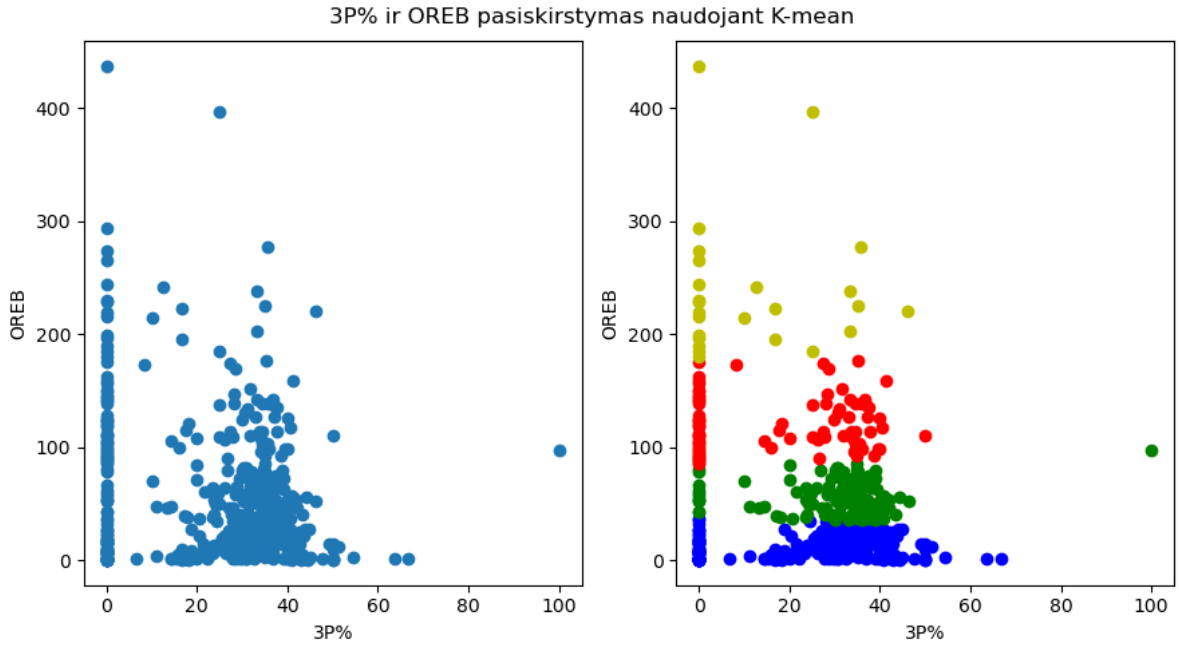


*Pav. 8 Duomenų klasterizavimas į keturis klasterius*

Kaip ir viršutiniuose bandymuose matome, kad grafikas pasiskirsto į keturias dalis. Duomenų pasiskirstymas ne vienodas, kadangi taškų pasiskirstymas nėra vienodas.

Antram bandymui naudojama pora yra įmestų tritaškių kiekis ir blokuoti metimai. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

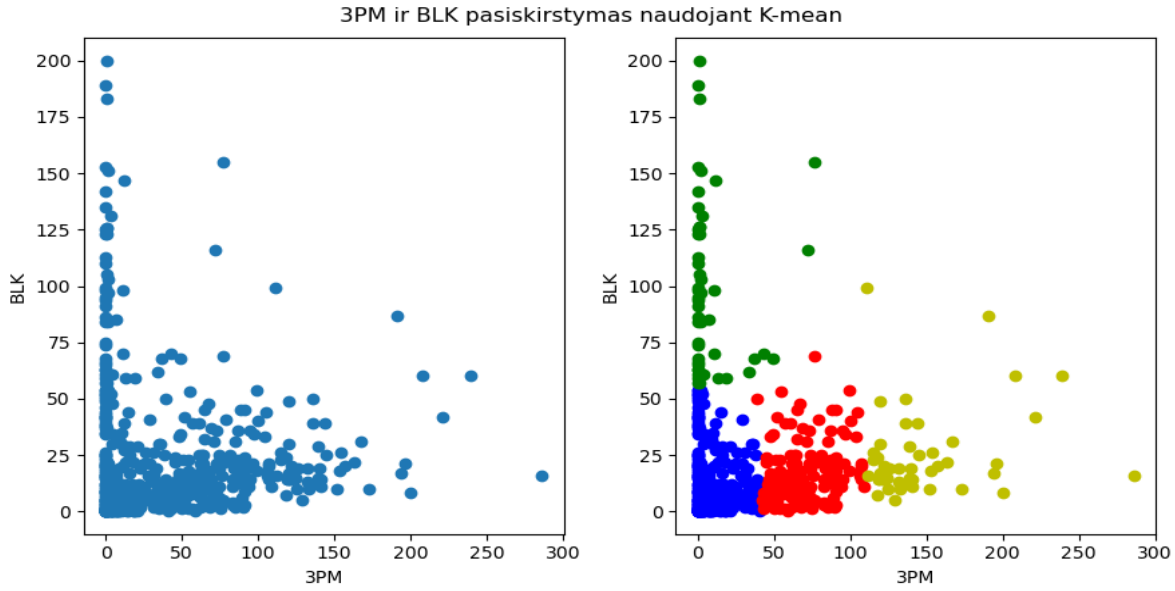


*Pav. 9 Duomenų klasterizavimas į keturis klasterius*

Atlikus antrą bandymą matome jog šitas bandymas pavyko geriausiai. Pasiskirstymas į grupes yra panašus. Grafike matosi jog rezultatai gavosi beveik kaip atskiros salelės.

Trečiam bandymui naudojama pora yra mestų tritaškių kiekis ir pavogtų kamuolių kiekis. Pirmieji duomenys naudojami kaip x ašies duomenys, antrieji duomenys naudojami kaip y ašies duomenys.

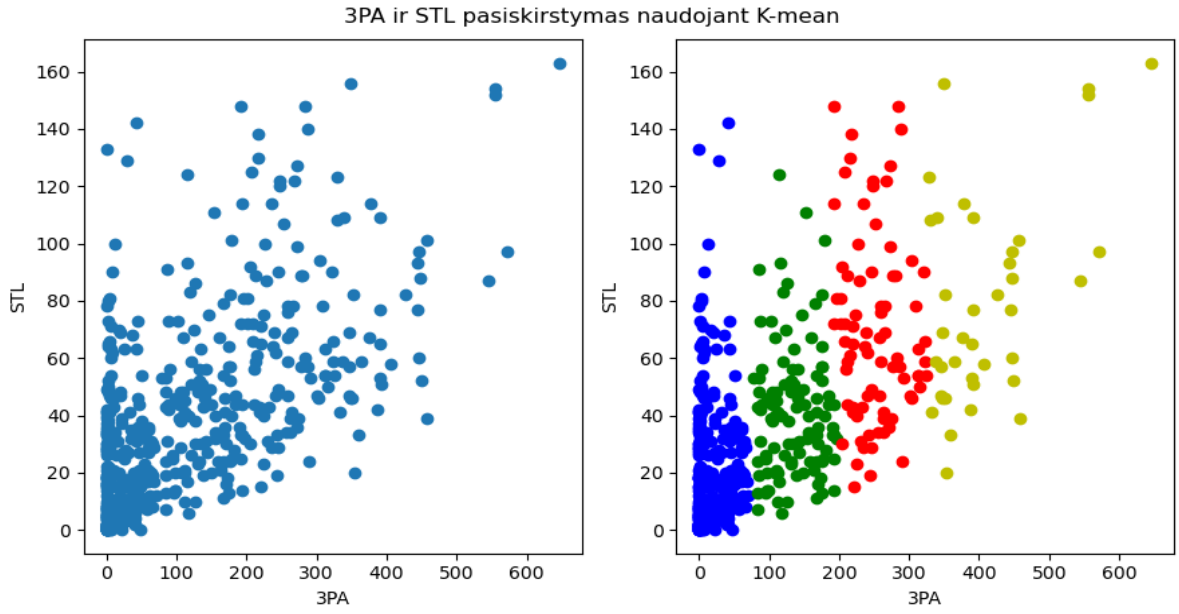


*Pav. 10 Duomenų klasterizavimas į keturis klasterius*

Paskutiniame bandyme taip pat grupių pasiskirstymas išryškėja daug geriau. Lyginant du grafikus galime pamatyti, kad taškai pasiskirsto į tokias saleles kurias galime pamatyti dar nepaskirstytame grafike.

# Modelio Analizė ir klasterių pasirinkimai

Modelio analizei naudosime Silhouette analizę ir sklearn python biblioteką su mano gautais rezultatais. Modelio analizę atliksime norėdami optimaliausią klasterių skaičių su pasirinktais duomenimis.

Modelio analizę išsamiau aprašysiu pirmiems bandymams, kadangi galima spręsti pagal gautus silhouette taškus. Po pirmojo bandymo grafikų aptarsime lentelę su likusiai rezultatais.

## Pirmas bandymas

Pirmasis grafikas aiškiai rodo jog pasiskirstymas nėra lygus, bet matome jo aiškiai atskirai grupes.

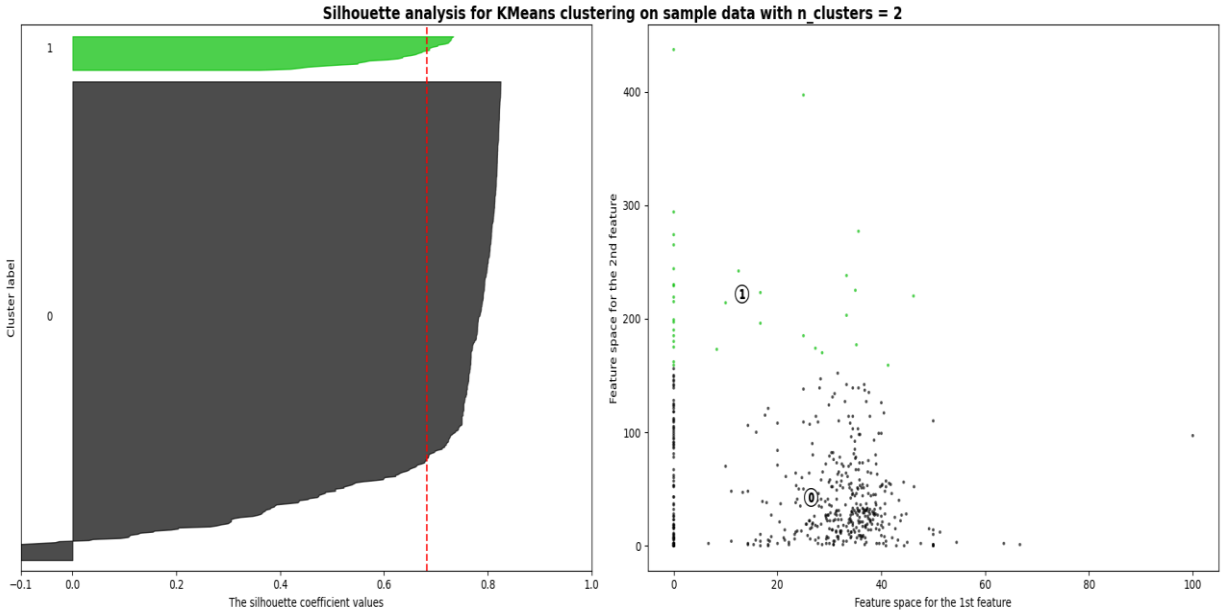


*Pav. 11 Pirmo bandymo analizės grafikas naudojant du klasterius*

Antrajame grafike matome vis dar aiškų trijų grupių pasiskirstymą. Nulinę grupę sudaro daugiausia taškų kaip ir pirmame grafike.

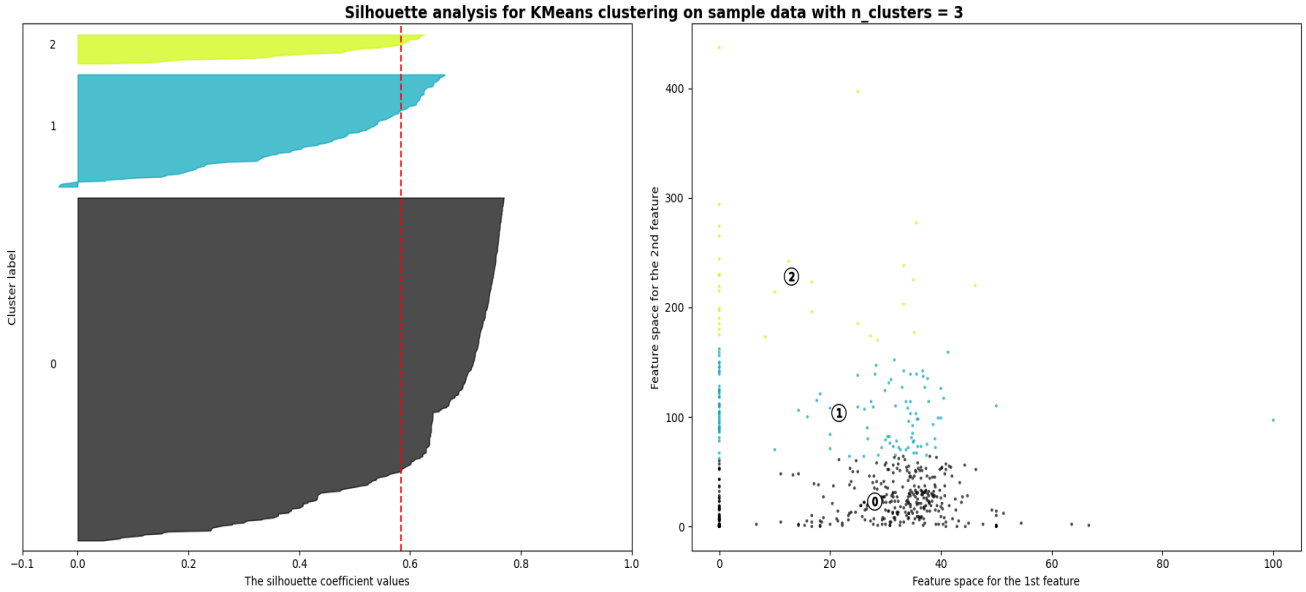


*Pav. 12 Pirmo bandymo analizės grafikas naudojant tris klasterius*

Trečiajame grafike pasiskirstymas vis dar matomas aiškiai. Taškų kiekis klasteriuose supanašėjo kaip ir koeficientu reikšmės.

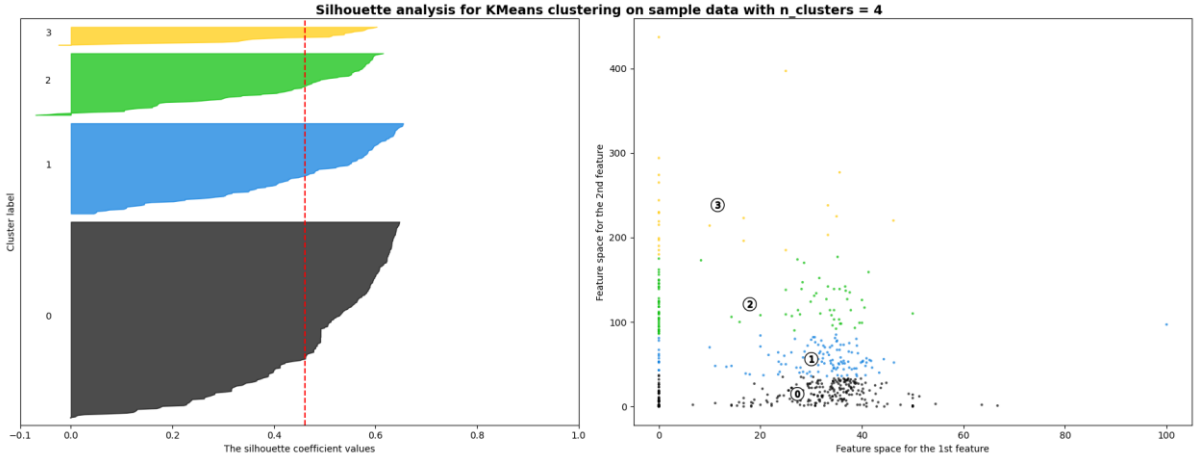


*Pav. 13 Pirmo bandymo analizės grafikas naudojant keturis klasterius*

Pagal šituos grafikus galime atskirti kokį kiekį klasterių reikėtu naudoti pirmam bandymui. Neatsižvelgiant į vidutinį silhouette įvertį matome jog mažiausiai pasikeitė pirmieji du grafikai. Atsižvelgiant į grafikus ir lentelę esančią apačioje galime spręsti jo geriausia pirmam bandymui yra naudoti du klasterius kadangi aiškiausiai atskiriamos grupės.

Pateiktoje lentelėje matome modelio įverčių vidurkius pagal kuriuos taip pat galima spręsti klasterių kiekį.

| Klasterių kiekis | Pirmo bandymo modelio vidutinis įverčiai | Antro bandymo modelio vidutinis įverčiai | Trečio bandymo modelio vidutinis įverčiai |
|---|---|---|---|
| 2 | 0.6825419882718818 | 0.5375989520508717 | 0.6062526551916785 |
| 3 | 0.5838175234374163 | 0.46715669986218095 | 0.602965962885443 |
| 4 | 0.4610331785394148 | 0.5356632274898092 | 0.5711744976147289 |

*Lentelė. 3 Modelio įverčių lentelė*

Lentelėje labai geria matosi kuriuos klasterius naudoti pasirinktuose bandymuose. Visoje lentelėje dominuoja antras klasteris. Trečio ir ketvirto klasterių įverčiai kinta, vienu atveju didesnis įvertis trečio, kitu atveju ketvirto.

## Antras bandymas

Grafikas aiškiai rodo jog pasiskirstymas nėra lygus, bet matome jo aiškiai atskirtos grupes viena nuo kitos. Atsižvelgiant į grafiką ir į įverčius antras klasteris yra geriausias antro bandymo naudojimui.

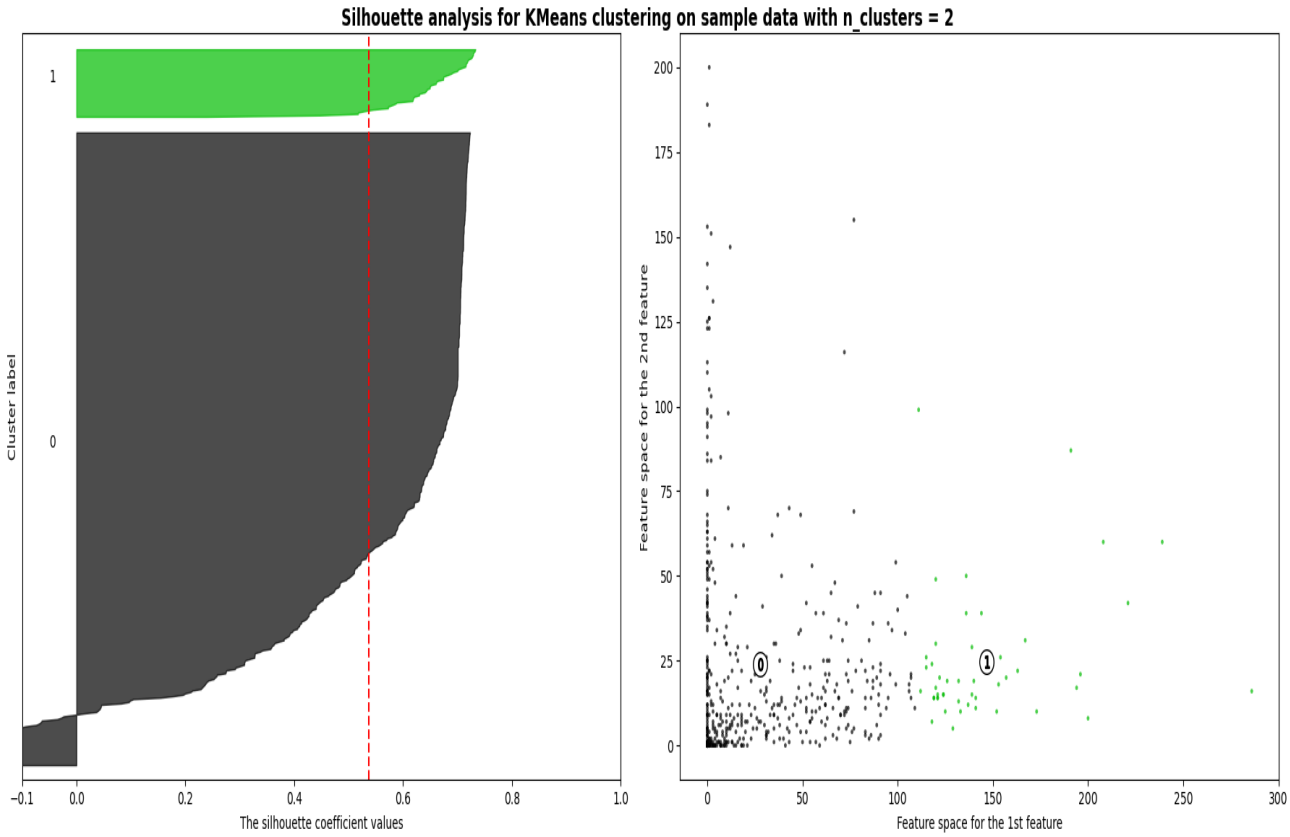


*Pav. 14 Antro bandymo analizės grafikas naudojant du klasterius*

Antrame grafike matome nemažus pasikeitimus. Paskutinioji grupė dar labiau sumažėjo. Grafike matomas grupių atskyrimas yra aiškus, Atsiradęs dydžių nepastovumas mažina įvertį esantį lentelėje.

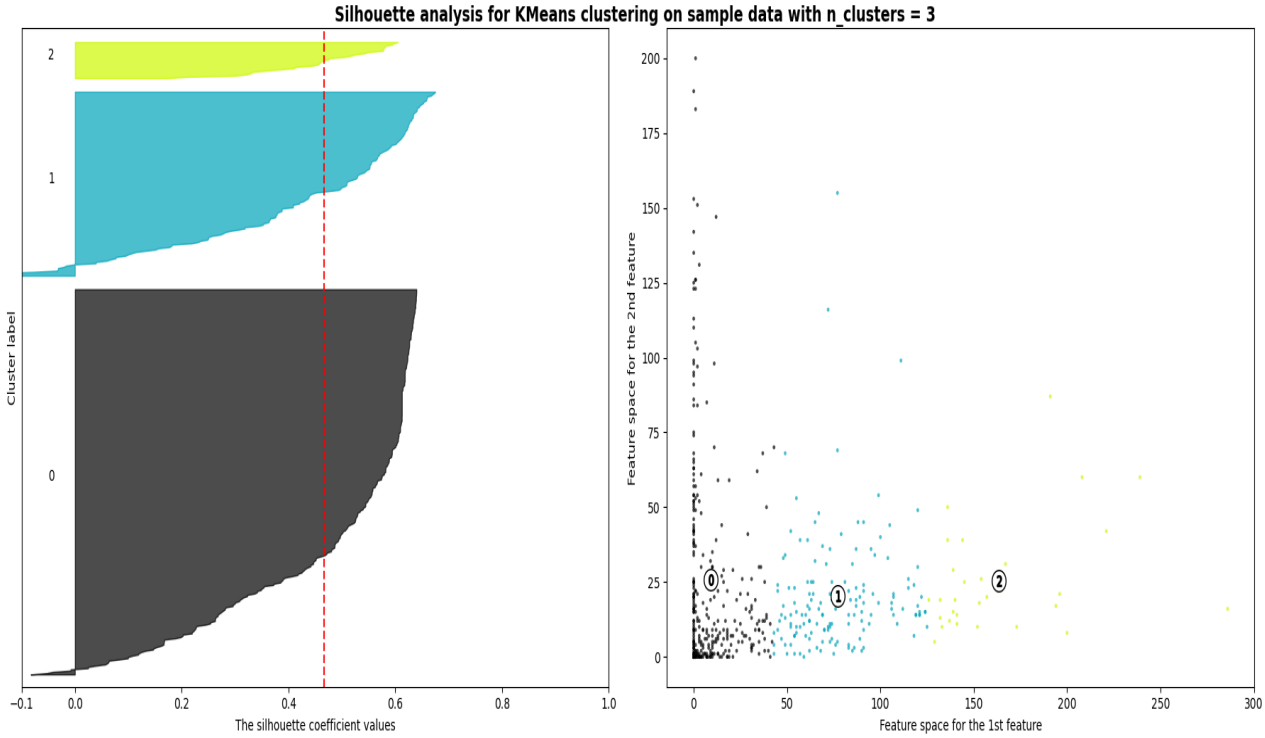


*Pav. 15 Antro bandymo analizės grafikas naudojant tris klasterius*

Trečiame grafike matome jog grupių dydžiai labiau pasiskirsto tarpusavyje. Geresnis pasiskirstymas grupėse gerina įvertį esantį lentelėje.

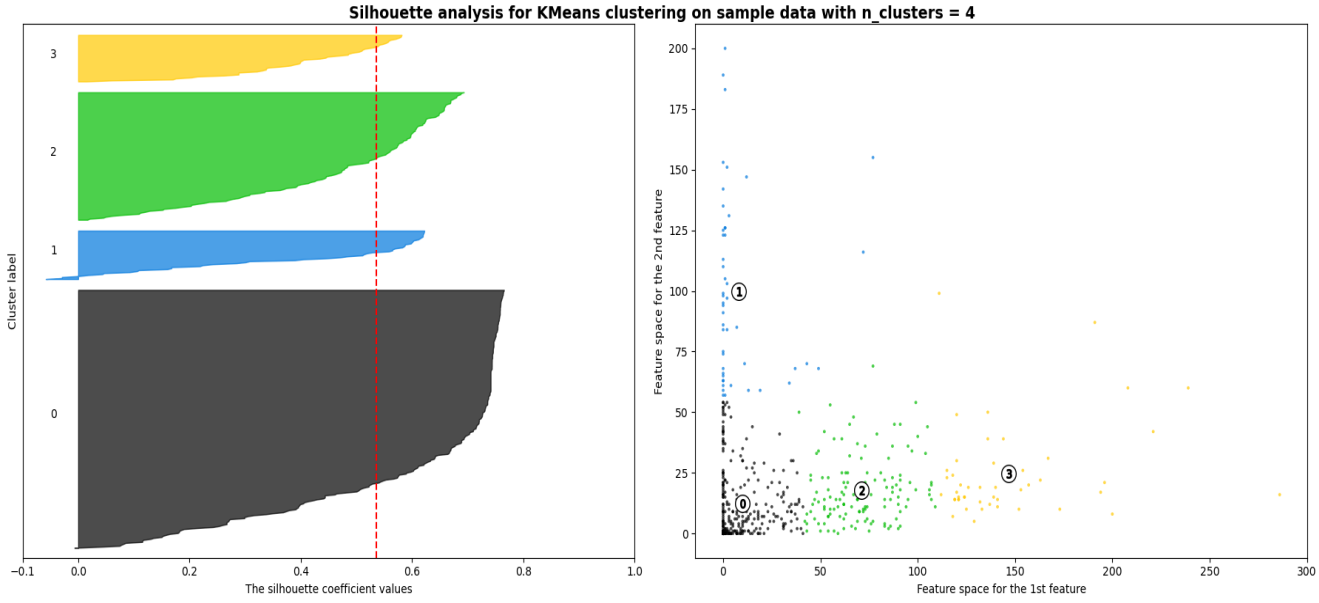


*Pav. 16 Antro bandymo analizės grafikas naudojant keturis klasterius*

Pagal duotus grafikus kurie yra aukščiau galime atskirti kokį kiekį klasterių reikėtu naudoti antram bandymui. Neatsižvelgiant į vidutinį silhouette įvertį matome jog visi grafikai skyrėsi daug, bet pirmas ir trečias grafikai yra geriausi. Pirmas grafiko grupės paskirstytos į aiškias dvi saleles vieną didelę ir vieną maža. Trečio grafiko salelės taip pat aiškiai atskirtos. Trečio grafiko salelių dydžiai yra panašūs. Dėl paminėtų priežasčių ir duotos lentelė aukščiau, geriausi pasirinkimai yra naudoti du arba keturis klasterius.

## Trečias bandymas

Grafikas aiškiai rodo jog pasiskirstymas nėra lygus, bet matome jo aiškiai atskirai grupes viena nuo kitos.

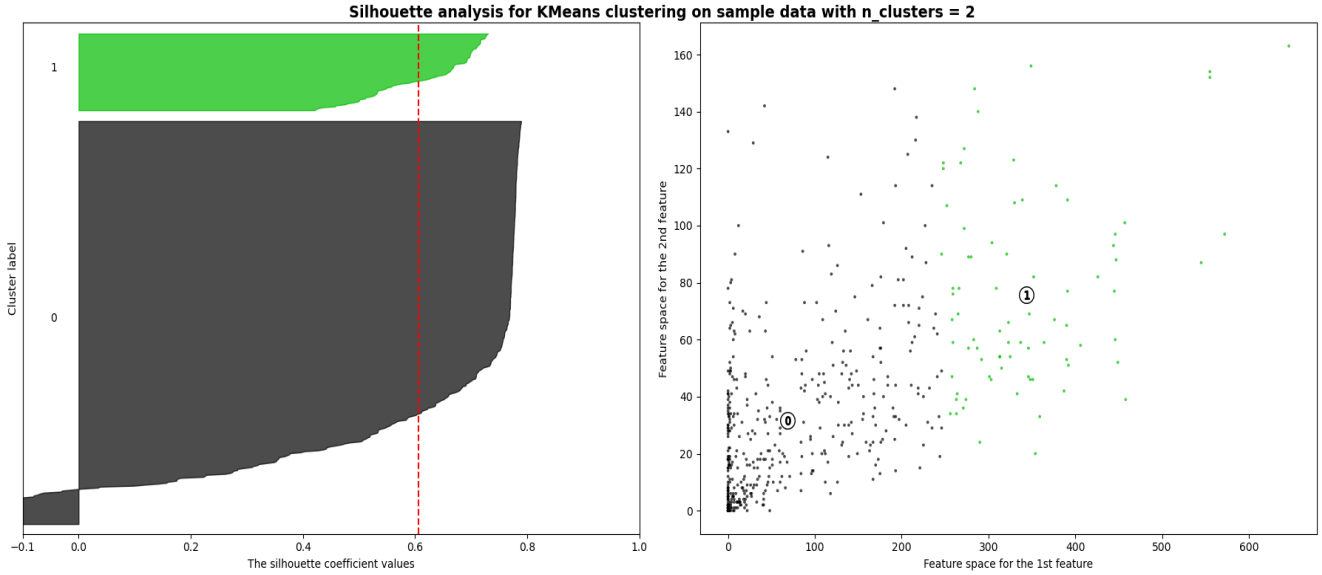


*Pav. 17 Trečio bandymo analizės grafikas naudojant du klasterius*

Antrame grafike matome, kad daugiausia taškų išlieka pirmoje grupėje, todėl stabilumas ir įvertis keičiasi labai mažai.

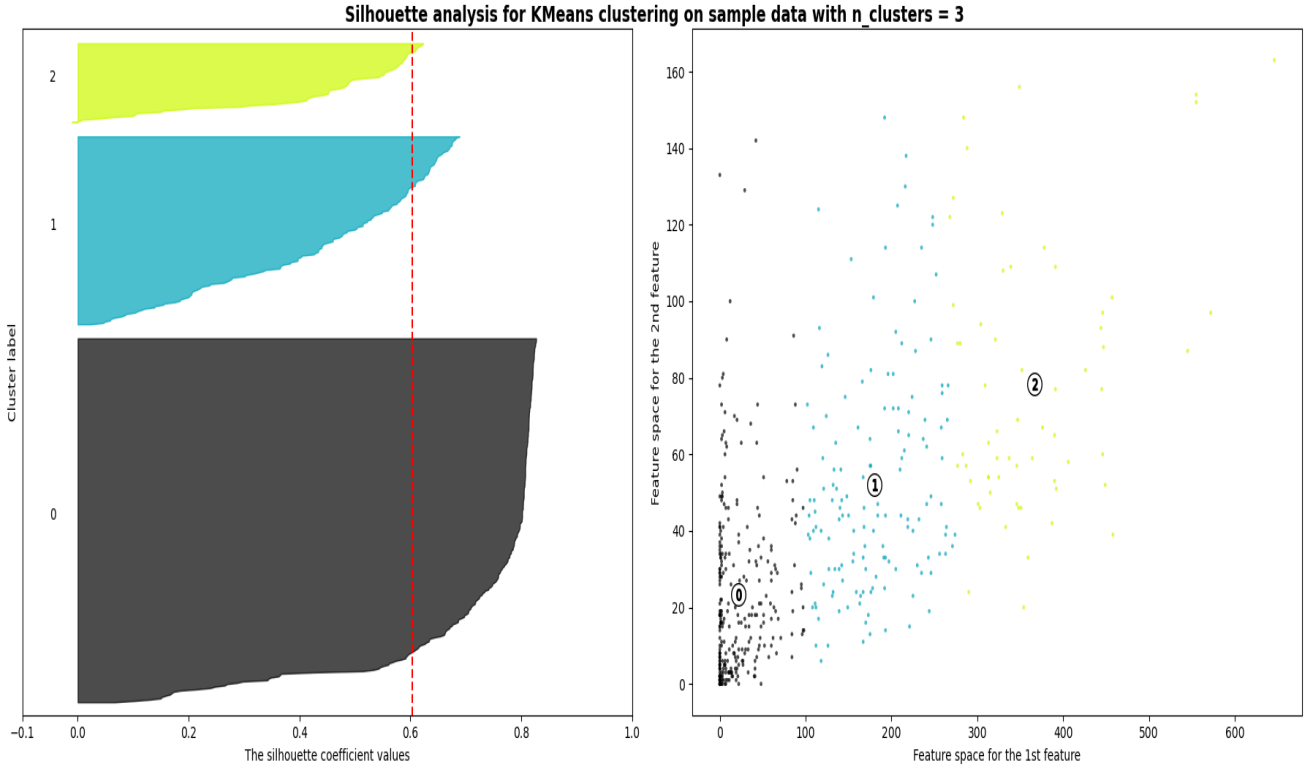


*Pav. 18 Trečio bandymo analizės grafikas naudojant tris klasterius*

Trečiame grafike taip pat matome kad daugiausia taškų išlieka pirmoje grupėje, todėl stabilumas ir įvertis keičiasi mažai kaip ir naudojant tris klasterius.

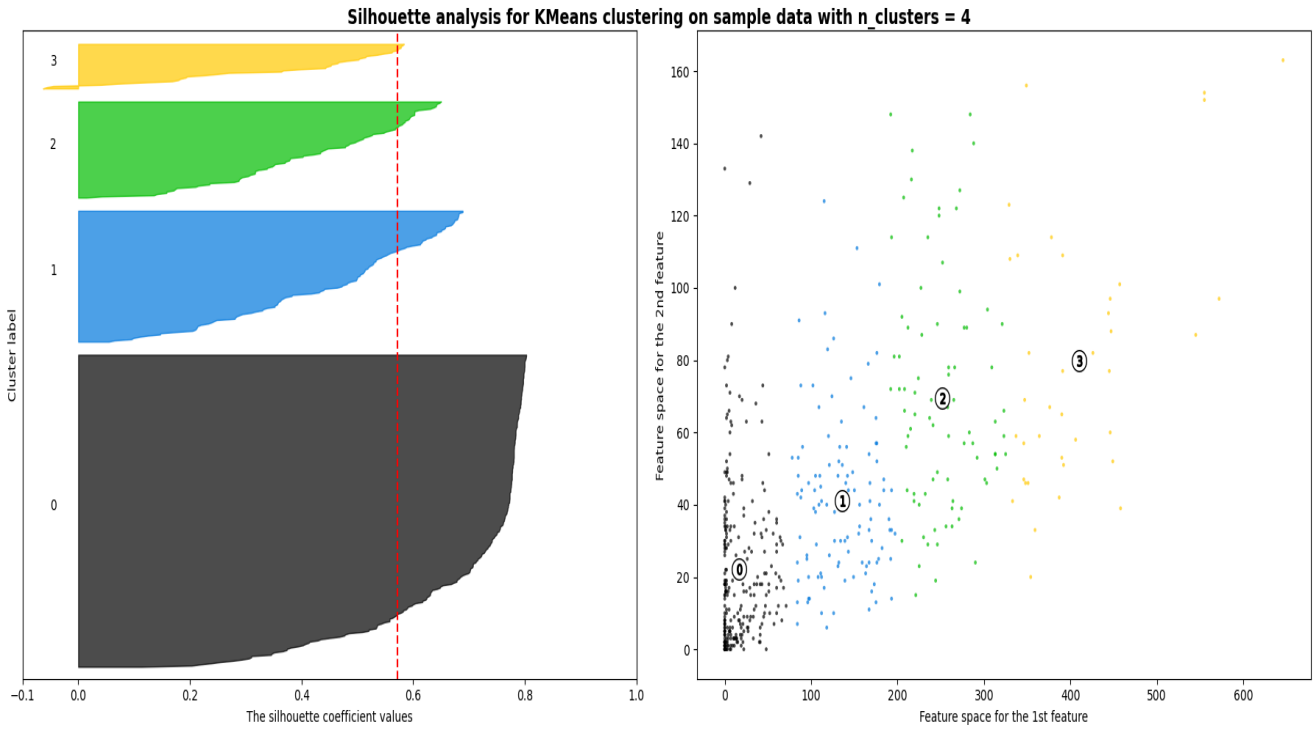


*Pav. 19 Trečio bandymo analizės grafikas naudojant keturis klasterius*

Pagal šituos grafikus galime atskirti kokį kiekį klasterių reikėtu naudoti trečiam bandymui. Neatsižvelgiant į vidutinį silhouette įvertį matome jog stabiliausi grafikai yra pirmas ir antras. Kaip ir pirmame bandyme pirmasis grafikas pasiskirstęs į didelę ir mažą grupes. Antras grafikas yra pasiskirstęs į dvi panašias grupes ir trečią didelę. Pasirinktas klasterių kiekis atsižvelgiant į grafikus butų du arba trys klasteriai. Renkantis klasterių kiekį atsižvelgus į grafikus ir aukščiau duotą lentelę klasterių pasirinkimas nesikeičia.

## Dalinė išvada

Išanalizavę visus grafikus matome jog klasterių pasirinkimą įtakoja daug veiksnių. Grafiko pasiskirstymas yra vienas iš didžiausių veiksnių, jei grafikas pasiskirstęs į daug mažų salelių tai greičiausiai geriau naudoti bus didesnį klasterių kiekį. Pirmųjų centroidų pasirinkimas taip pat įtakoja klasterių kiekį. Blogai pasirinkus centroidu taškus galima gauti blogą klasterių paskirstymą kuris įtakoja klasterių kiekį. Mano atveju centroidai buvo pasirinkti tokie, kad jų atstumas būtu panašus.

# Išvados

Išsiaiškinau kaip naudojamas ir kam naudojamas K-mean algoritmas. Praktiškai pavyko realizuoti K-mean algoritmą naudojantis NBA 2014-2015m. duomenis. Duomenim suklasterizuoti naudojau du, tris ir keturis klasterius. Naudojant skirtingų dydžio klasterius pastebėjau jog duomenys klasteriuose pasiskirsto nevienodai. Taškų pasiskirstymą klasteriuose lemia klasterių skaičius, pačių taškų pasiskirstymas grafike ir pasirinkti centroidai. Geriausias klasterių kiekis gali būti nustatytas naudojantis analizės metodais kaip “Silhouette analysis”. Analizė duoda įverčius ir grafikus pagal kuriuos galime pasirinkti optimalų klasterių kiekį. Mano pasirinkti duomenys nebuvo geriausi, kadangi taškų pasiskirstymas grafike buvo kaip vieną didelė grupė. Klasterizavimo algoritmas rado skirtingas salas, bet lyginant grafikus nebuvo aiškiai matomų salelių. Panaudojus algoritmą ir atlikus analizę supratau jog šitas algoritmas skirtas atskiroms grupėms sudaryti ir sudarytų grupių panaudojimui. Pasirinkus geresnius NBA duomenis galėjau žaidėjus suskaidyti į žaidėjų įgūdžių grupes.

# Programos kodas

## Kodas naudojamas išvestims

```
import csv
from pandas import DataFrame
import numpy as np
import matplotlib.pyplot as plot
import seaborn as sb
import math


def Heat(nameList, Data):
    fig, ax = plot.subplots(figsize=(15, 15))
    df = DataFrame(Data, columns=nameList)
    corrMatrix = df.corr()
    ax = sb.heatmap(corrMatrix, annot=True)
    plot.show()

class K_Means:

    def __init__(self, k=2, tol=0.001, max_iter=300):
        self.k = k
        self.tol = tol
        self.max_iter = max_iter

    def fit(self, data, centroids):

        self.centroids = {}

        for i in range(self.k):
            self.centroids[i] = centroids[i]

        for i in range(self.max_iter):
            self.classifications = {}
            self.labels_ = []
            for i in range(self.k):
                self.classifications[i] = []

            for featureset in data:
                distances = [np.linalg.norm(featureset - self.centroids[centroid])
for centroid in self.centroids]  # norm vektoriaus esme kaip normalus foras
                classification = distances.index(min(distances))  # gaunamas
indeksas
                self.labels_.append(classification) # pridedamas klasterio
indeksas
                self.classifications[classification].append(featureset)  #
nustatoma kuris klusteris

            prev_centroids = dict(self.centroids)

            for classification in self.classifications:
                self.centroids[classification] =
np.average(self.classifications[classification], axis=0)  # perskaiciuojami
centroidai

            optimized = True

            for c in self.centroids: # erroru skaiciavimas ir patikrinamas ar
```

```
testi skaiciavimus
                original_centroid = prev_centroids[c]
                current_centroid = self.centroids[c]
                if np.sum(original_centroid) > 0:
                    if (np.sum((current_centroid - original_centroid)) / np.sum(
                            original_centroid) * 100.0) > self.tol:
                        optimized = False
                else:
                    optimized = False


            if optimized:
                break

def sortBy(e): # saraso rikiavimo funkcija
    return math.pow((e[0] + e[1]),2)



dataList = [] # duomenu is failo nuskaitymas
with open('players_stats.csv') as csvfile:
  reader = csv.reader(csvfile)
  for row in reader:
        dataList.append(row)

dataUsingKey = {}
keys = [] # duomenu pavadinimai naudojami kaip raktai pasiekti duomenims
cnt = 0

# raktu panaudojimo paruosimas
for x in dataList[0]:
    if cnt > 0 and cnt < 22:
        dataUsingKey[x] = []
        keys.append(x)
    cnt = cnt + 1

index = 0
for x in dataList[1:]: # duomenu pridejimas i dictionary
    index = 0
    for a in x[1:22]:
        dataUsingKey[keys[index]].append(float(a))
        index = index + 1

Heat(keys, dataUsingKey) # heat map peisimas

range_n_clusters = [2, 3, 4, 5, 6] # klasteriu kiekiu sarasas
pairs = [[8,12], [6,17], [7,16]] # naudojamu prou indeksai

class K_Means:

    def __init__(self, k=2, tol=0.001, max_iter=300):
        self.k = k
        self.tol = tol
        self.max_iter = max_iter

    def fit(self, data, centroids):

        self.centroids = {}
```

```
        for i in range(self.k):
            self.centroids[i] = centroids[i]

        for i in range(self.max_iter):
            self.classifications = {}
            self.labels_ = []
            for i in range(self.k):
                self.classifications[i] = []

            for featureset in data:
                distances = [np.linalg.norm(featureset - self.centroids[centroid])
for centroid in self.centroids]  # skaičiuojamas atstumas tap taškų
                classification = distances.index(min(distances))  # gaunamas
indeksas
                self.labels_.append(classification) # pridedamas klasterio
indeksas
                self.classifications[classification].append(featureset)  #
kordinačių įdėjimas į klasterį

            prev_centroids = dict(self.centroids)

            for classification in self.classifications:
                self.centroids[classification] =
np.average(self.classifications[classification], axis=0)  # perskaiciuojami
centroidai

            optimized = True

            for c in self.centroids: # erorų skaičiavimas ir patikrinamas ar tęsti
skaičiavimus
                original_centroid = prev_centroids[c]
                current_centroid = self.centroids[c]
                if np.sum(original_centroid) > 0:
                    if (np.sum((current_centroid - original_centroid)) / np.sum(
                            original_centroid) * 100.0) > self.tol:
                        optimized = False
                else:
                    optimized = False


            if optimized:
                break

def sortBy(e): # sarašo rikiavimo funkcija
    return math.pow((e[0] + e[1]),2)



dataList = [] # duomenų is failo nuskaitymas
with open('players_stats.csv') as csvfile:
  reader = csv.reader(csvfile)
  for row in reader:
        dataList.append(row)

dataUsingKey = {}
keys = [] # duomenų pavadinimai naudojami kaip raktai pasiekti duomenims
cnt = 0

# raktų panaudojimo paruošimas
```

```
for x in dataList[0]:
    if cnt > 0 and cnt < 22:
        dataUsingKey[x] = []
        keys.append(x)
    cnt = cnt + 1

index = 0
for x in dataList[1:]: # duomenų pridėjimas į dictionary
    index = 0
    for a in x[1:22]:
        dataUsingKey[keys[index]].append(float(a))
        index = index + 1

range_n_clusters = [2, 3, 4, 5, 6] # klasterių kiekių sarašas
pairs = [[8,12], [6,17], [7,16]] # naudojamu proų indeksai

for i in range(len(pairs)):

    x_index = pairs[i][0]
    y_index = pairs[i][1]

    dataSorting = []
    coordinates = []
    data = []

    # sarašo paruošimas centroidų paieškai
    for a in range(len(dataUsingKey[keys[y_index]])):
        dataSorting.append([dataUsingKey[keys[x_index]][a],
dataUsingKey[keys[y_index]][a]])
        data.append([dataUsingKey[keys[x_index]][a],
dataUsingKey[keys[y_index]][a]])

    dataSorting.sort(key=sortBy)

    for k_count in range_n_clusters:

        # centroidu paieška atsižvelgiant į klasterių kiekį
        init_centroids = [[dataSorting[0][0], dataSorting[0][1]]]
        if k_count > 2:
            splitTo = int(len(dataSorting) / (k_count - 1))
            x = splitTo
            while x < splitTo * (k_count - 1):
                init_centroids.append([dataSorting[x][0], dataSorting[x][1]])
                x = x + splitTo

        init_centroids.append([dataSorting[len(dataSorting) - 1][0],
dataSorting[len(dataSorting) - 1][1]])

        # sukurto modelio panaudojimas
        kmeans = K_Means(k_count)
        kmeans.fit(np.array(data), np.array(init_centroids))
        lables = kmeans.labels_

        # x ir y reikšmių formatavimas grafiko naudojimui
        dataXAfter = []
        dataYAfter = []
        for a in kmeans.classifications:
            dataXAfter.append([])
            dataYAfter.append([])
```

```
            for classification in kmeans.classifications[a]:
                dataXAfter[a].append(classification[0])
                dataYAfter[a].append(classification[1])

        # dviejų grafikų piešimas
        fig, (ax0, ax1) = plot.subplots(nrows=1, ncols=2, figsize=(9, 5,))
        # grafikas skirtas neskirtytiems duomenims atvaizduoti
        ax0.scatter(dataUsingKey[keys[x_index]], dataUsingKey[keys[y_index]])
        # grafikai skirti atvaizduoti sugrupuotus duomenis
        if k_count > 1:
            ax1.scatter(dataXAfter[0], dataYAfter[0], c='b')
        if k_count > 1:
            ax1.scatter(dataXAfter[1], dataYAfter[1], c='g')
        if k_count > 2:
            ax1.scatter(dataXAfter[2], dataYAfter[2], c='r')
        if k_count > 3:
            ax1.scatter(dataXAfter[3], dataYAfter[3], c='y')
        if k_count > 4:
            ax1.scatter(dataXAfter[4], dataYAfter[4], c='m')
        if k_count > 5:
            ax1.scatter(dataXAfter[5], dataYAfter[5], c='c')
        ax1.set_xlabel(keys[x_index])
        ax1.set_ylabel(keys[y_index])
        ax0.set_xlabel(keys[x_index])
        ax0.set_ylabel(keys[y_index])
        ax0.set_title(" ")
        ax1.set_title(" ")
        fig.suptitle( keys[x_index] +" ir "+ keys[y_index] +" pasiskirstymas
naudojant K-mean")

plot.tight_layout()
plot.show()
```

### Kodas naudojamas modelio validacijai

```
from sklearn.metrics import silhouette_samples, silhouette_score
import matplotlib.pyplot as plt
import matplotlib.cm as cm
import numpy as np
import csv
import math

class K_Means:

    def __init__(self, k=2, tol=0.001, max_iter=300):
        self.k = k
        self.tol = tol
        self.max_iter = max_iter

    def fit(self, data, centroids):

        self.centroids = {}

        for i in range(self.k):
            self.centroids[i] = centroids[i]

        for i in range(self.max_iter):
            self.classifications = {}
            self.labels_ = []
```

```
            for i in range(self.k):
                self.classifications[i] = []

            for featureset in data:
                distances = [np.linalg.norm(featureset - self.centroids[centroid])
for centroid in self.centroids]  # skaičiuojamas atstumas tap taškų
                classification = distances.index(min(distances))  # gaunamas
indeksas
                self.labels_.append(classification) # pridedamas klasterio
indeksas
                self.classifications[classification].append(featureset)  #
kordinačių įdėjimas į klasterį

            prev_centroids = dict(self.centroids)

            for classification in self.classifications:
                self.centroids[classification] =
np.average(self.classifications[classification], axis=0)  # perskaiciuojami
centroidai

            optimized = True

            for c in self.centroids: # erorų skaičiavimas ir patikrinamas ar tęsti
skaičiavimus
                original_centroid = prev_centroids[c]
                current_centroid = self.centroids[c]
                if np.sum(original_centroid) > 0:
                    if (np.sum((current_centroid - original_centroid)) / np.sum(
                            original_centroid) * 100.0) > self.tol:
                        optimized = False
                else:
                    optimized = False


            if optimized:
                break

def sortBy(e): # sarašo rikiavimo funkcija
    return math.pow((e[0] + e[1]),2)



dataList = [] # duomenų is failo nuskaitymas
with open('players_stats.csv') as csvfile:
  reader = csv.reader(csvfile)
  for row in reader:
        dataList.append(row)

dataUsingKey = {}
keys = [] # duomenų pavadinimai naudojami kaip raktai pasiekti duomenims
cnt = 0

# raktų panaudojimo paruošimas
for x in dataList[0]:
    if cnt > 0 and cnt < 22:
        dataUsingKey[x] = []
        keys.append(x)
    cnt = cnt + 1
```

```
index = 0
for x in dataList[1:]: # duomenų pridėjimas į dictionary
    index = 0
    for a in x[1:22]:
        dataUsingKey[keys[index]].append(float(a))
        index = index + 1

range_n_clusters = [2, 3, 4, 5, 6] # klasterių kiekių sarašas
pairs = [[8,12], [6,17], [7,16]] # naudojamu proų indeksai

for i in range(len(pairs)):

    print("bandymas nr. " + str(i) + " ----------------------")
    x_index = pairs[i][0]
    y_index = pairs[i][1]

    dataSorting = []
    coordinates = []
    data = []

    # sarašo paruošimas centroidų paieškai
    for a in range(len(dataUsingKey[keys[y_index]])):
        dataSorting.append([dataUsingKey[keys[x_index]][a],
dataUsingKey[keys[y_index]][a]])
        data.append([dataUsingKey[keys[x_index]][a],
dataUsingKey[keys[y_index]][a]])
    data = np.array(data)
    dataSorting.sort(key=sortBy)

    for n_clusters in range_n_clusters:

        # centroidu paieška atsižvelgiant į klasterių kiekį
        init_centroids = [[dataSorting[0][0], dataSorting[0][1]]]
        if n_clusters > 2:
            splitTo = int(len(dataSorting) / (n_clusters - 1))
            x = splitTo
            while x < splitTo * (n_clusters - 1):
                init_centroids.append([dataSorting[x][0], dataSorting[x][1]])
                x = x + splitTo

        init_centroids.append([dataSorting[len(dataSorting) - 1][0],
dataSorting[len(dataSorting) - 1][1]])
        init_centroids = np.array(init_centroids)

        # sukuriamas grafikas su dviejais sub grafikais
        fig, (ax1, ax2) = plt.subplots(1, 2)
        fig.set_size_inches(18, 7)

        ax1.set_xlim([-0.1, 1])

        ax1.set_ylim([0, len(data) + (n_clusters + 1) * 10])

        # sukurto modelio panaudojimas
        clusterer = K_Means(n_clusters)
        clusterer.fit(data, init_centroids)
        cluster_labels = np.array(clusterer.labels_)

        # centroidu paruošimas naudojimu silhouette analizei
        centers = []
```

```
        for a in clusterer.centroids:
            centers.append([clusterer.centroids[a][0], clusterer.centroids[a][1]])
        centers = np.array(centers)

        # silhouette analizes panaudojimas įverčiui gauti
        silhouette_avg = silhouette_score(data, cluster_labels)
        print("For n_clusters =", n_clusters,
              "The average silhouette_score is :", silhouette_avg)

        # paskaičiuoti įvertį kiekvienam taškui
        sample_silhouette_values = silhouette_samples(data, cluster_labels)

        y_lower = 10
        for i in range(n_clusters):
            # agreguoti įvererčius naudojanmus pasirinktam klasteriui
            ith_cluster_silhouette_values = \
                sample_silhouette_values[cluster_labels == i]

            ith_cluster_silhouette_values.sort()

            size_cluster_i = ith_cluster_silhouette_values.shape[0]
            y_upper = y_lower + size_cluster_i

            color = cm.nipy_spectral(float(i) / n_clusters)
            ax1.fill_betweenx(np.arange(y_lower, y_upper), 0,
ith_cluster_silhouette_values, facecolor=color, edgecolor=color, alpha=0.7)

            # legendos teksto sudarymas
            ax1.text(-0.05, y_lower + 0.5 * size_cluster_i, str(i))

            # paskaičiauoti nauja y apatini kuris naudojamas legendos tekstui
            y_lower = y_upper + 10

        ax1.set_title(" ")
        ax1.set_xlabel("The silhouette coefficient values")
        ax1.set_ylabel("Cluster label")

        # Raudona vertikali linija parodyti vidutiniam analizės įverčiui
        ax1.axvline(x=silhouette_avg, color="red", linestyle="--")

        ax1.set_yticks([])
        ax1.set_xticks([-0.1, 0, 0.2, 0.4, 0.6, 0.8, 1])

        # piešiamas antras grafikas pavaizduoti sugrupuotus taškus
        colors = cm.nipy_spectral(np.array(cluster_labels).astype(float) /
n_clusters)
        ax2.scatter(data[:, 0], data[:, 1], marker='.', s=30, lw=0, alpha=0.7,
                    c=colors, edgecolor='k')

        # nupiešti centroido rutuliukus
        ax2.scatter(centers[:, 0], centers[:, 1], marker='o',
                    c="white", alpha=1, s=200, edgecolor='k')

        for i, c in enumerate(centers):
            ax2.scatter(c[0], c[1], marker='$%d$' % i, alpha=1,
                        s=50, edgecolor='k')

        ax2.set_title(" ")
        ax2.set_xlabel("Feature space for the 1st feature")
```

```
        ax2.set_ylabel("Feature space for the 2nd feature")

        plt.suptitle(("Silhouette analysis for KMeans clustering on sample data "
                      "with n_clusters = %d" % n_clusters),
                     fontsize=14, fontweight='bold')
    print("-----------------------------------------")

plt.show()
```