

1. Genetiniai algoritmai I dalis

Parengė: lekt. Neringa Dubauskienė

Ankstesniame video išgirdote apie tai, kas įkvėpė genetinių algoritmų sukūrimą, kas yra genai, chromosomos, populiacijos ir kodėl vykdoma atranka.

Antroje paskaitos apie genetinius algoritmus dalyje sužinosite kokius įrankius genetiniai algoritmai gali pasitelkti gautų sprendimų pagerinimui. Šioje paskaitoje kalbėsime apie tai:

- Kas yra rekombinacija
- Kas yra mutacija
- Kada užbaigiamas genetinis algoritmas
- Kam naudojami genetiniai algoritmai

Ankstesniame video kalbėjome apie tai, kad siekiant sudaryti geresnius sprendimus vykdoma esamų sprendimų atranka. Blieka išspręsti klausimą – o kurie sprendimai yra geresni? Tuo tikslu sudaroma tinkamumo funkcija. Aprašę idealaus sprendimo kriterijus matematiškai galime nustatyti, kaip toli kiekvienas sprendimas yra nuo pageidaujamo. Tinkamumo funkcija sudaroma taip, kad gautume aukštesnes vertes tikrindami geresnius sprendimus. Grįžtant prie gamyklos pavyzdžio- tie sprendimai, kurių dėka komandos trumpiau lauks laisvų įrenginių gaus aukštesnius tinkamumo funkcijos įvertinimus. Tinkamumo funkcija yra sudėtinė, nes privalo įvertinti visus kriterijus, kurie svarbūs geram sprendimui, priešingu atveju, gausime ne tokį rezultatą, kokio tikėjomės.

Sudarę pradinę populiaciją, galime rasti ir geresnių sprendimų – tam genetiniai algoritmai turi keletą įrankių. Vienas iš pagrindinių jų – rekombinacija. Sakoma, kad vaikai paveldi po pusę genų iš savo abiejų tėvų, gaudami atsitiktines genų kombinacijas, tokiu būdu tapdami unikaliais, nepakartojamais individais, bet kartu ir likdami panašūs į savo tėvus. Tą patį galima padaryti ir su mūsų sprendimais – paimti du galimus sprendimus, arba chromosomas, padalinti jas perpus ir tas puseles sujungti į naują sprendinį, arba chromosomą. Nebūtina dalinti griežtai perpus – galimos įvairios kombinacijos, padalinimo vietą parenkant atsitiktinai. Taip pat nebūtina chromosomų dalinti į dvi dalis, galima chromosomą padalinti į tris dalis, arba dvi chromosomas padalinti į nelygias dalis, tai yra, supjaustyti, taip gaunant skirtingo ilgio sprendinius. Rekombinacijos metu svarbu tai, kad naujai sudaryti sprendimai būtų prasmingi, tai yra, gauti tokius pačius kintamuosius, kokie buvo problemos aprašyme. Gamyklos pavyzdyje svarbu tai, kad komandoms nebūtų priskiriamas laikas po darbo valandų arba neegzistuojantys įrenginiai. Naujai gauti sprendiniai bus vadinami vaikais, o senieji sprendimai – tėviniais. Vaikai pridedami prie jau turimos populiacijos. Taigi, jei prieš tai turėti atsitiktinai gauti sprendimai mūsų gamyklos darbui organizuoti visas komandas paskyrė dirbti darbo dienos pabaigoje prie to paties įrenginio, bent dalis naujai gautų sprendimų tikėtina bus įvairesni, panašesni į mums reikalingus. Jei ne – vėl daliname chromosomas perpus ir sudarome iš jų naujus vaikus.

Rekombinacija nėra vienintelis įrankis naujiems sprendimams gauti. Jei gamtoje tik paveldėtume įvairias genų kombinacijas iš savo tėvų, naujos rūšys niekada neatsirastų, visi vaikai būtų labai panašūs į savo tėvus. Evoliucija ir naujų rūšių atsiradimas vyksta dėl atsitiktinės genų mutacijos – vienas ar kitas genas organizme pasikeičia, taip gaunant netikėtas organizmo savybes.

Kai kurie iš šių pokyčių žalingi, trukdantys organizmams išgyventi, o kai kurie – naudingi. Tą patį galime padaryti ir su sprendimais – imti ir pakeisti keletą genų atsitiktiniu būdu. Jei chromosomos ketvirtas genas prieš tai buvo vienetukas – keičiame jį į nuliuką ir atvirkščiai. Galima pakeisti ir daugiau nei vieną geną, priklausomai nuo to, kokios įvairovės sprendinių mūsų problemai reikia. Tokiu būdu gausime netikėtus sprendinius, kurie bus mažai panašūs į anksčiau sudarytus.

Jei nebūtų mutacijos – gautume sprendimus, kurie, nors galimai ir neblogi, nėra patys geriausi. Jei naudotume tik mutaciją – paieška vyktų atsitiktinai, be krypties, tikintis netyčia aptikti gerą sprendimą. Naudojant abu įrankius, galima išlaikyti balansą tarp kryptingos, nuoseklios paieškos, ir netikėtų geresnių sprendimų radimo. Šio balanso išlaikymas ir yra genetinių algoritmų kūrimo iššūkis – kiekvienai problemai reikia rasti savą algoritmo taikymą.

Be mutacijos ir rekombinacijos, genetiniai algoritmai turi ir daugiau įrankių, dauguma kurių yra tam tikros minėtų dviejų įrankių variacijos.

Tikėtina, kad to vieno idealaus sprendimo, kuris atitiktų visas iškeltas sąlygas, taip niekada ir nerasime, bet daugeliui problemų tinka ir pakankamai geri sprendimai. Naudodami tinkamumo funkciją populiacijos dydį išlaikome visada tokį patį, su kiekvienu nauju algoritmo ciklu gaudami vis geresnius sprendimus. Algoritmui skaičiuojant vis iš naujo, galiausiai nutiks vienas iš dviejų dalykų – tinkamumo funkcijos dėka pasieksime nustatytą idealų sprendinį, arba, kas labiau tikėtina – kiekviena nauja karta bus tokio paties tinkamumo kaip ir ankstesnioji, tai yra, naujai gauti sprendimai nebebus geresni už anksčiau rastus. Tokiu atveju laikas stabdyti skaičiavimus. Jei pagal surastą vienos kartos sprendimą komanda numeris vienas prie užduoties dirbs dienos pradžioje, o komanda numeris keturi – pabaigoje, o pagal sekančios kartos sprendimą – atvirkščiai, esminio skirtumo tarp šių sprendimų nėra, tai tik to paties sprendimo variacija. Tolimesni skaičiavimai tada tērą laiko ir kitų resursų švaistymas.

Jei rasti sprendiniai tinka naudojimui – puiku, dirbtinis intelektas savo tikslą pasiekė. Jei ne – laikas peržiūrėti algoritmą, ir ieškoti naujo balanso tarp rekombinacijos ir mutacijos, o galbūt tikslinti tinkamumo funkciją ar ieškoti dar kitokių patobulinimų.

Taigi, susipažinome su pagrindiniais genetinio algoritmo žingsniais. Pats algoritmas schematiškai pavaizduotas skaidrėje. Nepaisant algoritmo paprastumo, kiekvienas jo žingsnis reikalauja tinkamo suderinimo, kad gautas sprendimas būtų panaudojamas.

Įvairių grafikų, tvarkaraščių ir maršrutų sudarymas – genetiniams algoritmams puikiai tinkančios užduotys. Kita įdomi šių algoritmų pritaikymo sritis – robotika. Šiuo atveju evoliuciniai algoritmai naudojami autonominių robotų navigacijos apmokymui. Naujų mikroschemų kūrimui taip pat galima panaudoti evoliucinius algoritmus, kurių dėka mikroschemos elementai išdėliojami taip, kad būtų gaunami dar mažesni ir spartesni įrenginiai. Pagrindinis genetinių algoritmų privalumas, lyginant su panašiais kitokiais algoritmais yra jų savybė eliminuoti blogus sprendimus ir pagerinti gerus. Tais atvejais, kai kiti algoritmai užstringa ties sąlyginai gerais sprendimais, tikėtina, kad genetinių algoritmų pagalba galima tikėtis šiuos sprendimus pagerinti. Genetiniai algoritmai taip pat gali būti tik nedidelė dalis kompleksinio problemos sprendimo ir naudojami kartu su kitais algoritmais.

Svarbu žinoti ir tai, kad genetiniai algoritmai yra vieni iš prieštaringai vertinamų dirbtinio intelekto mokslininkų bendruomenėje. Nepaisant gana elegantiško jų sudarymo ir intuityviai suprantamų sprendimo priėmimo procesų, teigiama, kad didelė dalis šių algoritmų pasiekimų labiau priklauso nuo jų programuotojų įgūdžių ir gero problemos išmanymo, o ne paties algoritmo galimybių. Parinkti genetinio algoritmo parametrus taip, kad gautas sprendimas būtų priimtinas yra nelengva

užduotis, stipriai sąlygojama sprendžiamos problemos tipo. Dalis tyrėjų teigia, kad tą patį rezultatą galima gauti ir paprasčiau, bet nepaisant to, genetiniai ir kiti evoliuciniai algoritmai turi savo nišą ir išlaiko nors ir ne patį didžiausią, bet pakankamą susidomėjimą dirbtinio intelekto mokslininkų bendruomenėje.